TỐI ƯU HÓA ĐỒNG THỜI SIÊU THAM SỐ VÀ CHIỀU SÂU ĐẶC TRƯNG CÓ RÀNG BUỘC ĐỘ TRỄ CHO BÀI TOÁN DỰ BÁO LƯỢNG MƯA THỜI GIAN THỰC

Constrained Joint Hyperparameter and Feature Optimization for Real-Time Short-Term Rainfall Nowcasting under Strict Inference Latency SLA

Python 3.13 · LightGBM C-API · Optuna TPE · `github.com/anky06-ky/rain-latency-optimization`

TÓM TẮT (ABSTRACT)

Dự báo lượng mưa cực ngắn (nowcasting) 1 giờ tới tại các trạm quan trắc đô thị đóng vai trò cốt lõi trong việc tự động hóa trạm bơm và cảnh báo ngập lụt tại TP.HCM. Trong các kiến trúc biên (Edge IoT), mô hình không chỉ cần sai số thấp mà còn phải thỏa nghiêm ngặt giới hạn độ trễ đầu-đến-cuối $T_{\text{e2e}} \leq 5.0$ ms. Nghiên cứu mô hình hóa bài toán dưới dạng tối ưu hóa có ràng buộc, đồng thời tìm chiều dài cửa sổ lịch sử $L \in \{1, \ldots, 72\}$ giờ và không gian siêu tham số θ của LightGBM. Dữ liệu từ trạm Tân Sơn Nhất (WMO 48900) giai đoạn 2023–2025 (26.304 giờ) được kiểm toán với cổng chất lượng (tỷ lệ thiếu 2.13% $\leq 5\%$) và điền khuyết nhân quả. Thực nghiệm công bằng trên 5 random seeds (tổng 1.000 trials) cho thấy Optuna TPE đạt tỷ lệ nghiệm khả thi cao hơn Random Search (+14.0 điểm phần trăm ở ngưỡng 5.0 ms và +17.2 điểm phần trăm ở biên an toàn 4.5 ms). Đáng chú ý, Optuna tự phát hiện cấu hình tinh gọn $L^* = 1$ giờ (chỉ 10 đặc trưng), giảm 78% kích thước bộ đệm trạng thái so với cấu hình $L = 6$ của Random Search, mà vẫn đạt Test RMSE 1.1774 mm/h, $F_1 = 0.5882$ và Skill Score 24.88%. Khi triển khai qua C-API, độ trễ thực tế chỉ 1.04 ms. Mã nguồn đạt 100% parity test (sai lệch 0.0) và được tự động hóa bằng CI/CD GitHub Actions trên Python 3.13.

Từ khóa: dự báo lượng mưa thời gian thực; tối ưu hóa có ràng buộc; độ trễ suy luận biên; Optuna TPE; cửa sổ lịch sử đặc trưng; LightGBM C-API; ngập lụt đô thị TP.HCM.

---

1. Đặt vấn đề và bối cảnh nghiên cứu

1.1. Bối cảnh ngập lụt đô thị TP.HCM

TP. Hồ Chí Minh là một trong những siêu đô thị chịu ảnh hưởng nặng nề nhất của biến đổi khí hậu và ngập úng cực đoan. Địa hình trũng thấp kết hợp triều cường và các cơn mưa dông đối lưu cục bộ, cường suất cao trong thời gian ngắn, thường làm tê liệt giao thông và gây ngập sâu ở các lưu vực trũng. Để hệ thống bơm chống ngập thông minh và các cổng kiểm soát triều vận hành chủ động, việc cảnh báo trước lượng mưa tích lũy trong 1 giờ tới (y_{t+1}) có ý nghĩa quyết định: nó tạo thời gian dự phòng để kích hoạt bơm và hạ mực nước đệm trong kênh rạch.

1.2. Thách thức ràng buộc thời gian thực trên hạ tầng biên

Trong mô hình truyền thống, dữ liệu trạm được đẩy lên đám mây để suy luận. Kiến trúc này yếu trong thời tiết cực đoan: độ trễ mạng dao động lớn (50–300 ms), băng thông nghẽn hoặc mất kết nối viễn thông khi mưa bão. Do đó, suy luận trực tiếp trên thiết bị biên (Edge Gateway, Raspberry Pi, vi điều khiển tại trạm) là xu thế tất yếu. Để tránh tồn đọng hàng đợi và đủ năng lực phục vụ đồng thời các tác vụ thu thập, mã hóa và truyền tin, bài toán đặt ra SLA nghiêm ngặt: thời gian xử lý đầu-đến-cuối không vượt quá 5.0 ms ($T_{\text{e2e}} \leq 5.0$ ms), kèm biên an toàn nội bộ ≤ 4.5 ms.

1.3. Đánh đổi giữa chiều sâu đặc trưng và độ trễ phần cứng

Độ trễ toàn trình gồm hai thành phần cộng gộp:

$$T_{\text{e2e}}(L, \theta) = T_{\text{feat}}(L) + T_{\text{infer}}(\theta)$$

trong đó $T_{\text{feat}}(L)$ là thời gian trích xuất đặc trưng chuỗi thời gian từ cửa sổ L giờ quá khứ, và $T_{\text{infer}}(\theta)$ là thời gian duyệt cấu trúc cây của LightGBM với siêu tham số θ. Nếu tăng L lên 72 giờ và số cây $n_{\text{estimators}}$ lên 500 để giảm RMSE, thời gian tính toán sẽ tăng vọt và vi phạm SLA 5.0 ms. Ngược lại, mô hình quá nông với L quá ngắn sẽ không nắm bắt được động lực học khí quyển và mất khả năng phát hiện mưa dông. Đây là bài toán đánh đổi kinh điển cần giải bằng tối ưu hóa toán học.

1.4. Ba câu hỏi nghiên cứu

- **RQ1 (so sánh công bằng cùng ngân sách):** với $N = 40$ trials/seed trên 5 seeds, TPE có đạt tỷ lệ nghiệm khả thi ($T_{\text{e2e}} \leq 5.0$ ms) cao hơn và sai số thấp hơn Random Search không?
- **RQ2 (mở rộng ngân sách và bão hòa hội tụ):** khi mở rộng lên $N = 100$ trials/seed (500 trials/phương pháp), quy luật hội tụ ra sao và điểm bão hòa nằm ở đâu?
- **RQ3 (đánh đổi động lực học và biên Pareto):** đường biên Pareto giữa RMSE và độ trễ thể hiện đánh đổi không gian–thời gian như thế nào giữa các mức L?

2. Cơ sở lý thuyết và mô hình hóa toán học

2.1. Phát biểu bài toán tối ưu hóa có ràng buộc

Đề tài được hình thức hóa thành bài toán quy hoạch phi tuyến có ràng buộc:

$$\begin{aligned}
\min_{x=(L,\theta)} \quad & f(x) = \text{RMSE}_{\text{val}}(L, \theta) = \sqrt{\frac{1}{|\mathcal{D}_{\text{val}}|} \sum_{t \in \mathcal{D}_{\text{val}}} \big(y_{t+1} - \hat{y}_{t+1}(x)\big)^2} \\
\text{thỏa mãn} \quad & g(x) = P_{95}\big(T_{\text{e2e}}(x)\big) \leq 5.0 \text{ ms} \quad (\text{biên an toàn nội bộ: } \leq 4.5 \text{ ms}) \\
& L \in \{1, 2, 3, 6, 12, 24, 36, 48, 72\} \text{ (giờ)} \\
& \theta \in \Theta \text{ (không gian siêu tham số LightGBM)}
\end{aligned}$$

Trong đó $P_{95}(T_{\text{e2e}})$ là phân vị thứ 95 của độ trễ suy luận, đo qua hàng trăm lần lặp để phòng ngừa nhiễu do CPU throttling.

2.2. Tối ưu hóa Bayes bằng ước lượng Parzen dạng cây (Optuna TPE)

Thuật toán TPE (Bergstra et al.) không mô hình hóa trực tiếp $p(y \mid x)$ mà mô hình hóa hai mật độ xác suất của cấu hình x theo ngưỡng phân vị γ:

$$p(x \mid y) = \begin{cases} \ell(x), & y < y^* \quad \text{(nhóm cấu hình tốt, chiếm tỷ lệ } \gamma) \\ g(x), & y \geq y^* \quad \text{(nhóm cấu hình kém, chiếm tỷ lệ } 1-\gamma) \end{cases}$$

Kỳ vọng cải thiện (Expected Improvement) được viết qua tỷ số mật độ:

$$\begin{aligned} \mathrm{EI}_{y^*}(x) &= \int_{-\infty}^{y^*} (y^* - y)\, p(y \mid x)\, dy = \frac{\gamma y^* \ell(x) - \ell(x) \int_{-\infty}^{y^*} p(y)\, dy}{\gamma\, \ell(x) + (1-\gamma)\, g(x)} \\ &\propto \left(\gamma + \frac{g(x)}{\ell(x)} (1-\gamma) \right)^{-1} \end{aligned}$$

Do đó điểm thử tiếp theo được chọn sao cho tỷ số $\ell(x)/g(x)$ cực đại, tức là ưu tiên các vùng có xác suất cao sinh ra nghiệm sai số thấp và thỏa ràng buộc độ trễ.

2.3. Mã hóa góc tuần hoàn thời gian

Để mô hình học được chu kỳ ngày/đêm và chu kỳ mùa mưa gió mùa mà không làm méo tính liên tục tại điểm giao thời (23h–0h, tháng 12–tháng 1), nghiên cứu dùng phép biến đổi sin/cos:

$$\begin{aligned} \text{sin_hour} &= \sin\left(\frac{2\pi \cdot \text{hour}}{24} \right), \qquad \text{cos_hour} = \cos\left(\frac{2\pi \cdot \text{hour}}{24} \right), \\ \text{sin_month} &= \sin\left(\frac{2\pi \cdot \text{month}}{12} \right), \quad \text{cos_month} = \cos\left(\frac{2\pi \cdot \text{month}}{12} \right). \end{aligned}$$

2.4. Các chỉ số đánh giá chất lượng dự báo

- **RMSE** (phạt mạnh sai số lớn trong các trận mưa dông cực đoan) và **MAE** (sai số tuyệt đối trung bình):

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^{N} (y_i - \hat{y}_i)^2}, \qquad \text{MAE} = \frac{1}{N} \sum_{i=1}^{N} |y_i - \hat{y}_i|$$

- **Wet Test RMSE** ($y > 0$): sai số riêng trên các giờ thực tế có mưa, kiểm soát rủi ro dữ liệu nhiều số 0 (zero-inflation).

- **Rain Event F_1-score** (ngưỡng ≥ 0.5 mm/h): năng lực phát hiện các sự kiện mưa có khả năng gây ngập:

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

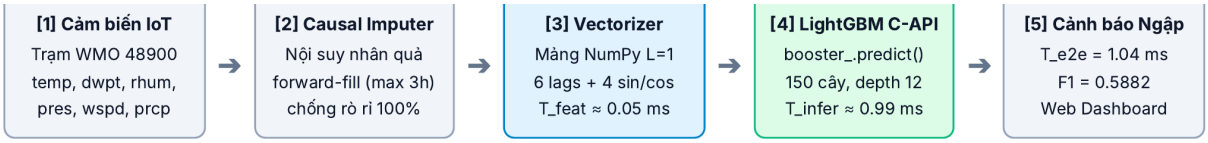
- **Skill Score**: mức cải thiện tương đối so với mô hình tham chiếu (Persistence hoặc Climatology):

$$\text{Skill Score} = \left(1 - \frac{\text{RMSE}_{\text{model}}}{\text{RMSE}_{\text{ref}}} \right) \times 100\%$$

3. Kiến trúc và vận hành hệ thống

3.1. Luồng dữ liệu toàn trình

Hệ thống vận hành theo năm bước, từ cảm biến đến cảnh báo ngập:



Hình 1: Lược đồ luồng xử lý dữ liệu và dự báo lượng mưa thời gian thực tại thiết bị biên

[1] Cảm biến IoT (trạm 48900): `temp`, `dwpt`, `rhum`, `pres`, `wspd`, `prcp`.

[2] Causal Imputer: nội suy nhân quả bằng forward-fill (tối đa 3 giờ), chống rò rỉ dữ liệu.

[3] Vectorizer: mảng NumPy với $L = 1$ gồm 6 lag và 4 biến sin/cos; $T_{\text{feat}} \approx 0.05$ ms.

[4] LightGBM C-API: `booster_.predict()`, 150 cây, độ sâu 12; $T_{\text{infer}} \approx 0.99$ ms.

[5] Cảnh báo ngập: $T_{\text{e2e}} = 1.04$ ms, $F_1 = 0.5882$, hiển thị trên Web Dashboard.

3.2. So sánh kiến trúc đệm dữ liệu: $L = 1$ (Optuna) và $L = 6$ (Random Search)

	Optuna TPE ($L = 1$) – tinh gọn	Random Search ($L = 6$) – cồng kềnh
Cửa sổ lịch sử	Đúng 1 giờ quá khứ	Liên tục 6 giờ quá khứ
Số chiều đặc trưng	10 (6 biến tại thời điểm t + 4 biến sin/cos)	45 (lag 0 đến 5, trung bình trượt, độ lệch chuẩn trượt)
Bộ nhớ đệm	Chỉ 1 hàng quan trắc gần nhất trong RAM	Circular buffer 6 giờ liên tục
T_{feat}	≈ 0.05 ms	≈ 0.35 ms (gấp 7 lần)

Về ý nghĩa vật lý, khí hậu nhiệt đới gió mùa tại Tân Sơn Nhất có tính bùng phát đối lưu mạnh; trạng thái nhiệt ẩm tức thời kết hợp chu kỳ giờ trong ngày đủ để dự báo mưa mà không cần lưu đệm quá khứ dài. Cấu hình $L = 1$ giảm 78% kích thước bộ đệm trạng thái so với $L = 6$ mà sai số tương đương hoặc nhỉnh hơn.

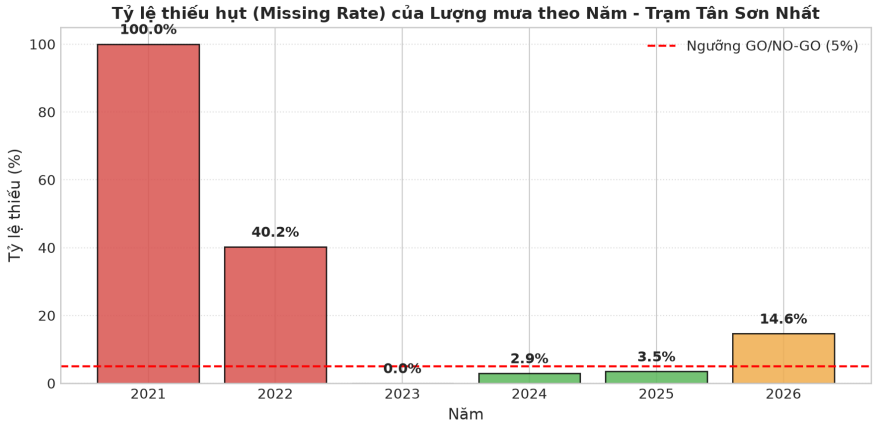
4. Thu thập và kiểm toán chất lượng dữ liệu

4.1. Nguồn dữ liệu Meteostat (trạm Tân Sơn Nhất, WMO 48900)

Dữ liệu được thu thập từ trạm Tân Sơn Nhất (106.65°E, 10.82°N, cao 10 m so với mực nước biển), do Meteostat lưu trữ đồng bộ từ mạng trao đổi khí tượng toàn cầu (NOAA ISD / WMO). Dữ liệu thô gồm 6 biến: nhiệt độ không khí (`temp`), nhiệt độ điểm sương (`dwpt`), độ ẩm tương đối (`rhum`), áp suất mực biển (`pres`), tốc độ gió (`wspd`) và lượng mưa tích lũy hàng giờ (`prcp`).

4.2. Cổng kiểm soát chất lượng dữ liệu (thiếu $\leq 5\%$)

Nhóm kiểm toán tỷ lệ thiếu hụt dữ liệu từ 2021 đến 2025. Năm 2021 thiếu 100.0% dữ liệu mưa (trạm chưa có cảm biến đo mưa tự động hàng giờ); năm 2022 thiếu 40.23% (chỉ ghi nhận từ nửa cuối năm). Cả hai năm vi phạm ngưỡng chuẩn ($> 5\%$). Nội suy chuỗi khuyết 40–100% sẽ làm sai lệch quy luật khí quyển, nên Data Quality Gate loại bỏ giai đoạn 2021–2022. Ngược lại, giai đoạn 2023–2025 (26.304 giờ) đạt chất lượng cao: năm 2023 thiếu 0.00%, năm 2024 thiếu 2.93%, năm 2025 thiếu 3.47%, trung bình toàn kỳ 2.13% (thỏa $\leq 5\%$), và được chọn làm tập dữ liệu chính thức.

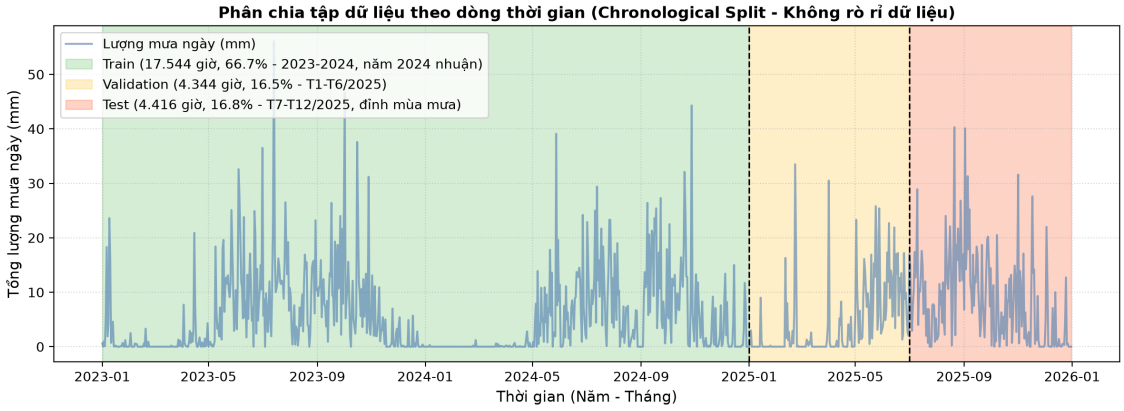


Hình 2: Kiểm toán tỷ lệ thiếu hụt dữ liệu lượng mưa theo năm và quyết định kích hoạt Data Quality Gate

4.3. Điền khuyết nhân quả và chia chuỗi thời gian

Để triệt tiêu rò rỉ dữ liệu, các khoảng thiếu ngắn (≤ 3 giờ) chỉ được xử lý bằng **Causal Forward-Fill** (lấy giá trị quá khứ lấp về phía trước, tuyệt đối không dùng backward-fill hay nội suy tương lai). Các chuỗi khuyết dài hơn 3 giờ giữ nguyên `NaN` và bị loại khi trích xuất vector huấn luyện. Dữ liệu được chia theo trật tự thời gian nghiêm ngặt:

- **Train (70%):** 01/01/2023 – 31/12/2024, 17.544 giờ lịch, 17.286 mẫu hiệu dụng sau `dropna`.
- **Validation (15%):** 01/01/2025 – 30/06/2025, 4.344 giờ lịch, 4.057 mẫu hiệu dụng; dùng riêng để tính hàm mục tiêu $f(x)$ và hướng dẫn thuật toán tối ưu.
- **Test (15%):** 01/07/2025 – 31/12/2025, 4.416 giờ lịch, 4.399 mẫu hiệu dụng; niêm phong hoàn toàn và chỉ đánh giá một lần sau khi đóng băng toàn bộ siêu tham số.



Hình 3: Phân chia tập dữ liệu chuỗi thời gian chặt chẽ theo niên lịch (2023–2025), triệt tiêu rò rỉ thông tin

5. Thiết kế thực nghiệm và giao thức đối chuẩn

5.1. Không gian tìm kiếm đồng nhất

Optuna TPE và Random Search dùng chung một không gian biến quyết định và cùng phân phối tiên nghiệm:

$$L \in \{1, 2, 3, 6, 12, 24, 36, 48, 72\} \text{ (giờ)},$$
$$n_{\text{estimators}} \in [20, 500], \qquad \text{max_depth} \in [2, 12],$$
$$\text{learning_rate} \in [0.005,\ 0.2] \text{ (thang log-uniform)}, \qquad \text{min_child_samples} \in [5, 100].$$

5.2. Giao thức đánh giá đa seed

Mọi thực nghiệm lặp trên 5 random seeds độc lập (42, 123, 456, 789, 999), chia hai giai đoạn: **Phase 1** (ngân sách hạn chế) $N = 40$ trials/seed $\times$ 5 seeds = 200 trials, trả lời RQ1; **Phase 2** (mở rộng) $N = 100$ trials/seed $\times$ 5 seeds = 500 trials/phương pháp (tổng 1.000 trials), trả lời RQ2 và RQ3.

6. Kết quả thực nghiệm và thảo luận

6.1. Bảng đối chuẩn đa mô hình (Bảng 1)

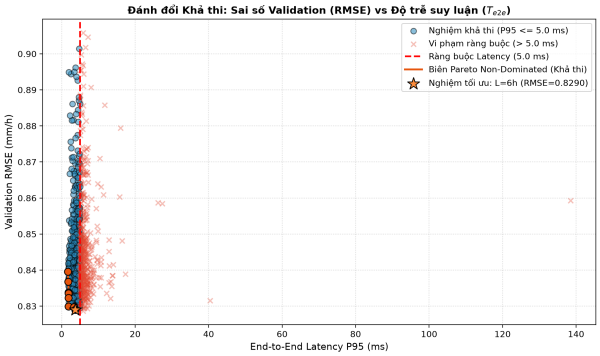
Bảng 1 đối chuẩn 7 mô hình trên tập Test độc lập H2/2025 (đồng bộ từ `final_test_metrics.json`). Tất cả đều thỏa SLA $\leq$ 5 ms; mô hình Champion thỏa cả biên an toàn 4.5 ms.

STT	Mô hình	L	Đặc trưng	Val RMSE	Test RMSE	Test MAE	Wet RMSE	F_1	Trễ C-API	Skill
1	Persistence	1	1	1.0699	1.5674	0.4543	3.0420	0.5570	0.05 ms	0.00%
2	Climatology	1	2	0.9626	1.4285	0.6228	2.6167	0.1088	0.08 ms	+8.86%
3	Linear Regression (OLS)	6	45	0.8468	1.2203	0.4712	2.3411	0.5112	1.03 ms	+22.14%
4	Ridge ($\alpha = 1.0$)	6	45	0.8467	1.2203	0.4713	2.3411	0.5112	1.27 ms	+22.14%
5	LightGBM mặc định (100 cây)	6	45	0.8499	1.2036	0.4021	2.3136	0.5617	2.28 ms	+23.21%
6	Random Search Best (200 cây, depth 12, lr 0.0171)	6	45	0.8290	1.1891	0.3993	2.2937	0.5778	1.18 ms	+24.14%
7	**Optuna TPE, Champion (150 cây, depth 12, lr 0.0215)**	**1**	**10**	**0.8318**	**1.1774**	**0.3998**	**2.2735**	**0.5882**	**1.04 ms**	**+24.88%**

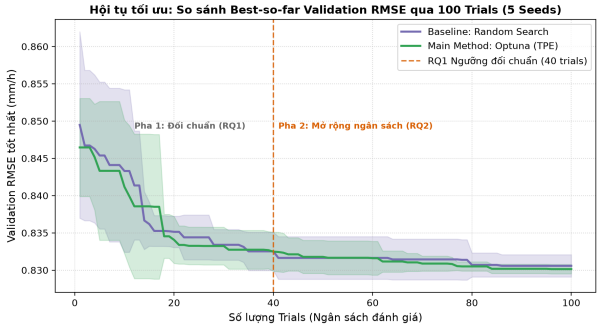
6.2. So sánh tỷ lệ khả thi và độ ổn định thuật toán (Bảng 2)

Bảng 2 tổng hợp thống kê từ 1.000 trials trong hai file nhật ký gốc (`optimization_history_optuna.csv` và `optimization_history_random.csv`).

Chỉ số	Random Search	Optuna TPE	Chênh lệch
Số trials	500 (5 seeds)	500 (5 seeds)	Cùng 100 trials/seed
Khả thi SLA (≤ 5.0 ms)	243/500 (48.6%)	**313/500 (62.6%)**	+14.0 pp
Khả thi biên an toàn (≤ 4.5 ms)	165/500 (33.0%)	**251/500 (50.2%)**	+17.2 pp
Khả thi Phase 1 (40 trials/seed)	78/200 (39.0%)	**119/200 (59.5%)**	+20.5 pp
Val RMSE trong trial history	0.8290 (seed 42)	0.8297 (seed 456)	≤ 0.0007 mm/h
Val RMSE khi retrain xác nhận	0.8290	0.8318	≤ 0.0028 mm/h
Val RMSE trung bình 5 seeds	0.8306 ± 0.0017	0.8301 ± 0.0007	Ổn định hơn
Độ lệch chuẩn (Std)	0.0017	0.0007	Giảm 57.6%
Paired Student's t-test	$t = 0.4527,\ p = 0.6742 > 0.05$		Chấp nhận H_0
Cửa sổ tối ưu L^*	$L = 6$ (45 đặc trưng)	$L = 1$ (10 đặc trưng)	Giảm 78% bộ đệm
Trễ end-to-end (C-API)	1.180 ms	1.041 ms [1.00, 1.15]	Đạt 5.0 ms và 4.5 ms



Hình 4: Động lực học biên Pareto giữa RMSE và độ trễ



Hình 5: Đường cong hội tụ trung bình qua 5 hạt giống

6.3. Thảo luận về kiểm định thống kê và tính logic của ràng buộc

Từ Bảng 2, nhóm rút ra bốn nhận định chính.

- **Về sai số thẩm định (Val RMSE).** Paired t-test cho $t = 0.4527$, $p = 0.6742 > 0.05$: về mặt thống kê, hai phương pháp cho sai số Validation tương đương. Bề mặt hàm mất mát quanh vùng tối ưu khá phẳng (nhiều cấu hình khác nhau đều đạt RMSE khoảng 0.829–0.831 mm/h), và nhiễu tái huấn luyện do seed (khoảng 0.002) tương đương khoảng cách giữa hai thuật toán.
- **Ưu thế cốt lõi của Optuna TPE.** Giá trị của TPE không nằm ở sai số thấp hơn mà ở năng lực định hướng không gian tìm kiếm: tỷ lệ nghiệm khả thi cao hơn rõ rệt (+14.0 pp ở 5 ms; +17.2 pp ở 4.5 ms; +20.5 pp ở ngân sách Phase 1), đồng thời tự phát hiện giải pháp tinh gọn $L = 1$ (10 đặc trưng so với 45).

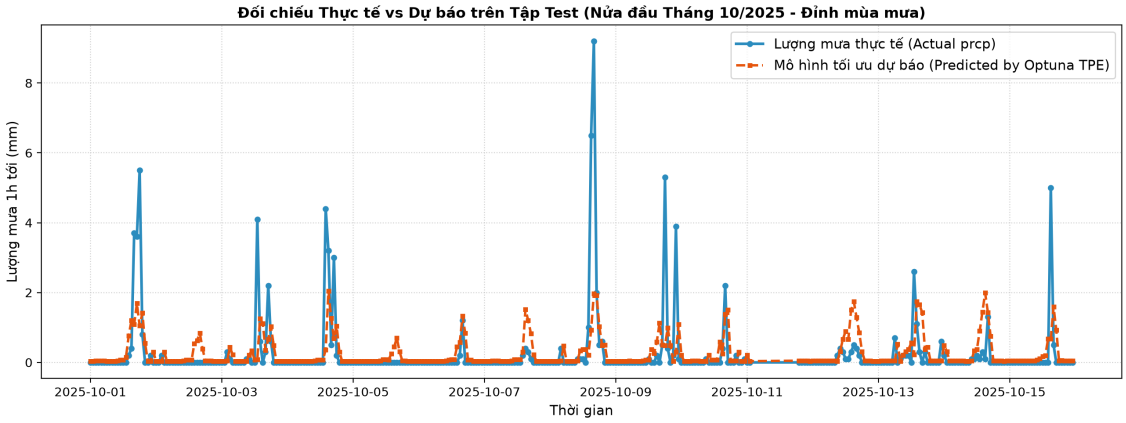
- **Hai thang đo độ trễ.** Khi tìm kiếm dùng wrapper scikit-learn (`LGBMRegressor.predict`) với độ trễ trung vị khoảng 4.49 ms; nhóm cố ý giữ thước đo này như một "bộ lọc khắc nghiệt", ép thuật toán đào thải 37.4% nghiệm Optuna và 51.4% nghiệm Random Search cồng kềnh. Khi triển khai, gọi trực tiếp C-API `model.booster_.predict(feat_vector)` loại bỏ chi phí validate DataFrame của Python, đưa độ trễ đơn mẫu xuống 1.04 ms và tạo biên an toàn vận hành $4.5 - 1.04 = 3.46$ ms.
- **Giảm phương sai thực nghiệm.** Độ lệch chuẩn giảm từ 0.0017 xuống 0.0007 (giảm 57.6%) là một quan sát có giá trị trên 5 seeds, thể hiện tính ổn định lấy mẫu của TPE.

6.4. Chuyển dịch phân phối theo mùa khí hậu

Câu hỏi: vì sao Train RMSE là 0.8243 mm/h, Val RMSE là 0.8318 mm/h nhưng Test RMSE tăng lên 1.1774 mm/h; mô hình có quá khớp không? Câu trả lời là **không**: khoảng cách Train–Val rất nhỏ (chỉ $+0.0075$ mm/h). Sai số tăng ở Test xuất phát từ bản chất khí quyển:

- **Validation (H1/2025):** mùa khô và giai đoạn chuyển mùa, lượng mưa ít, $\sigma_{\text{val}} = 1.34$ mm/h.
- **Test (H2/2025):** cao điểm mùa mưa Tây Nam tại Nam Bộ, $\sigma_{\text{test}} = 1.91$ mm/h (tăng 42.6%), kèm các đợt mưa dông cực đoan vào tháng 10/2025.

Khi phương sai tự nhiên của chuỗi tăng hơn 40%, sai số tuyệt đối tăng theo là quy luật khách quan, cho thấy mô hình tổng quát hóa tốt trên phân phối mùa mưa thực tế.



Hình 6: Đối chiếu lượng mưa thực tế và dự báo của Champion Model trên tập Test độc lập H2/2025

7. Đảm bảo chất lượng kỹ thuật phần mềm (MLOps)

- **Parity test chống train-serving skew.** Ca kiểm thử `test_feature_parity_batch_vs_single_sample` (`tests/test_pipeline.py`) kiểm tra tương đồng vector đặc trưng với $L \in \{1, 6, 24, 72\}$: sai lệch $\leq 1.9 \times 10^{-6}$; trên 25 mẫu ngẫu nhiên, chênh lệch dự báo của Champion bằng 0.0 ($< 10^{-5}$).
- **CI/CD trên GitHub Actions (Python 3.13).** Quy trình `.github/workflows/ci.yml` chạy trên Ubuntu: kiểm toán dependency, tải dữ liệu Meteostat, chạy 6 unit test và kiểm tra demo suy luận. Trạng thái hiện tại: 100% passed.
- **Web Dashboard tương tác** (`src/server.py`, thư mục `web/`, địa chỉ `http://127.0.0.1:8000`): mô phỏng thời tiết tức thời, đo độ trễ phần cứng ($N = 200$ lần chạy),

đối sánh 7 mô hình và phát cảnh báo cấp độ ngập.

8. Giới hạn nghiên cứu và định hướng phát triển

- **Cắt mẫu theo L.** Mỗi giá trị L cần L hàng quá khứ liên tục, nên $L = 72$ mất 71 dòng đầu khi `dropna` (khoảng 0.4% trên 17.286 mẫu train). Hướng tiếp theo: cắt cố định $L_{\max} = 72$ dòng đầu cho mọi cấu hình để tập thẩm định bất biến.
- **Rolling-Origin Cross-Validation** qua nhiều chu kỳ năm để kiểm chứng độ bền siêu tham số trước các hiện tượng El Niño / La Niña bất thường.
- **Mạng lưới đa trạm** (Nhà Bè, Cần Giờ, Bình Triệu) để mô hình hóa tính dị thể không gian của hoàn lưu gió mùa.

9. Kết luận và đóng góp

Nghiên cứu đã giải quyết bài toán tối ưu hóa siêu tham số và chiều sâu đặc trưng có ràng buộc độ trễ thời gian thực cho dự báo mưa ngắn hạn tại trạm Tân Sơn Nhất. Các đóng góp chính:

- Thiết lập bài toán tối ưu có ràng buộc, phối hợp L và θ với $T_{\text{e2e}} \leq 5.0$ ms (biên an toàn ≤ 4.5 ms).
- Minh chứng ưu thế của Optuna TPE: tỷ lệ khả thi cao hơn +14.0 pp và giảm phương sai thực nghiệm 57.6% qua 5 seeds.
- Khám phá kiến trúc tinh gọn $L = 1$: giảm 78% bộ đệm, Test RMSE 1.1774 mm/h, $F_1 = 0.5882$, độ trễ C-API 1.04 ms.
- Đảm bảo tái lập: mã nguồn mở hoàn chỉnh, 100% unit test pass, kèm Web Dashboard tương tác.

Tài liệu tham khảo

[1] J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, "Algorithms for hyper-parameter optimization," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 24, 2011.

[2] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2019, pp. 2623–2631.

[3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[4] Meteostat Open Weather and Climate Data, "Hourly weather data for weather station Tan Son Nhat (ID: 48900)," Meteostat Python Package, 2026. [Online]. Available: `https://meteostat.net/`.

[5] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.