BÁO CÁO BÀI TẬP LỚN · HỌC PHẦN NHẬP MÔN TỐI ƯU HÓA · TRƯỜNG ĐẠI HỌC VĂN LANG

TỐI ƯU HÓA ĐỒNG THỜI SIÊU THAM SỐ VÀ CHIỀU SÂU ĐẶC TRƯNG CÓ RÀNG BUỘC ĐỘ TRỄ CHO BÀI TOÁN DỰ BÁO LƯỢNG MƯA THỜI GIAN THỰC

Constrained Joint Hyperparameter and Feature Optimization for Real-Time Short-Term Rainfall Nowcasting under Strict Inference Latency SLA

Học phần: Nhập môn Tối ưu hóa | *Đơn vị:* Khoa Công nghệ Thông tin, Trường Đại học Văn Lang | *Trạm:* Tân Sơn Nhất (WMO 48900)

Mã nguồn: `https://github.com/anky06-ky/rain-latency-optimization` • Python 3.13 · LightGBM 4.7.0 · Optuna 5.0.0

TÓM TẮT

Dự báo lượng mưa 1 giờ tới tại trạm Tân Sơn Nhất phục vụ cảnh báo ngập cho TP.HCM, với yêu cầu mô hình vừa chính xác vừa chạy đủ nhanh: độ trễ suy luận đầu-cuối $P_{95}(T_{\text{e2e}}) \leq 5.0$ ms trên CPU đơn luồng. Bài tập lớn mô hình hóa yêu cầu này thành **bài toán tối ưu có ràng buộc**: tìm đồng thời độ dài cửa sổ lịch sử L và các siêu tham số θ của LightGBM để cực tiểu RMSE trên tập Validation. Dữ liệu Meteostat giai đoạn 2023–2025 (26.304 giờ) qua cổng kiểm soát chất lượng (tỷ lệ thiếu dữ liệu mưa mỗi năm $\leq 5\%$, trung bình 2.13%) và điền khuyết nhân quả. Bài toán được giải bằng **Optuna TPE** có ràng buộc và so sánh với Random Search, mỗi phương pháp 100 trial × 5 seed. Hai phương pháp đạt Val RMSE tốt nhất tương đương (0.8297 so với 0.8290). TPE có tỷ lệ cấu hình thỏa ràng buộc cao hơn (62.4% so với 48.6%), nhưng chênh lệch tính theo từng seed chưa có ý nghĩa thống kê và phần lớn đến từ việc TPE ưu tiên cửa sổ ngắn. Nghiệm TPE chọn được rất gọn: $L^* = 1$ giờ với 10 đặc trưng, so với 45 đặc trưng ở $L = 6$ của Random Search. Trên tập Test độc lập (mùa mưa H2/2025), mô hình đạt RMSE 1.1774 mm/h và $F_1 = 0.5882$, giảm 24.9% sai số so với Persistence và 4.7% so với Climatology, với độ trễ triển khai $P_{95} = 0.683$ ms.

Từ khóa: Tối ưu hóa có ràng buộc; Tối ưu Bayes; Optuna TPE; Siêu tham số; LightGBM; Độ trễ suy luận; Dự báo lượng mưa; TP.HCM.

1. ĐẶT VẤN ĐỀ & BỐI CẢNH

1.1. Bối cảnh Ngập lụt Đô thị TP.HCM và Nhu cầu Cảnh báo Sớm Cận Thực

TP. Hồ Chí Minh là một trong những siêu đô thị chịu ảnh hưởng nặng nề nhất bởi biến đổi khí hậu và hiện tượng ngập úng cực đoan. Địa hình trũng thấp kết hợp triều cường và các cơn mưa dông nhiệt đới cục bộ (đối lưu nhiệt) với cường suất cao trong thời gian ngắn thường xuyên làm tê liệt hệ thống giao thông và ngập sâu các lưu vực trũng. Để hệ thống bơm chống ngập thông minh và các cổng kiểm soát triều vận hành chủ động, việc cảnh báo trước lượng mưa tích lũy trong 1 giờ tới (y_{t+1}) có ý nghĩa quyết định nhằm tạo thời gian dự phòng kích hoạt máy bơm và hạ mực nước đệm trong kênh rạch.

1.2. Thách thức Ràng buộc Thời gian thực trên Hạ tầng Biên (Edge Computing)

Trong mô hình triển khai truyền thống, dữ liệu trạm quan trắc được đẩy lên máy chủ đám mây (Cloud) để suy luận. Tuy nhiên, kiến trúc này bộc lộ điểm yếu chết người trong các tình huống thời tiết cực đoan: độ trễ truyền gói tin qua mạng (network round-trip time) dao động lớn (50–300 ms), băng thông bị nghẽn hoặc mất kết nối viễn thông khi mưa bão lớn. Do đó, việc triển khai suy luận trực tiếp trên thiết bị tính toán biên (Edge Gateway / Raspberry Pi / Vi điều khiển tại trạm) là xu thế tất yếu.

Tại trạm biên, hệ thống liên tục tiếp nhận luồng dữ liệu thời tiết với tần suất cao. Để đảm bảo hệ thống không bị tồn đọng hàng đợi (queue blocking) và đủ năng lực phục vụ đồng thời các tác vụ thu thập, mã hóa và truyền tin cảnh báo, bài toán đặt ra **Thỏa thuận Mức Dịch vụ (SLA) nghiêm ngặt: Thời gian xử lý từ đầu-đến-cuối (End-to-End Latency) không được vượt quá 5.0 mili-giây** ($T_{\text{e2e}} \leq 5.0$ ms), đi kèm **Biên an toàn nội bộ (Safety Margin)** ≤ 4.5 ms.

1.3. Sự Đánh đổi Giữa Chiều sâu Đặc trưng và Độ trễ Phần cứng

Độ trễ toàn trình T_{e2e} gồm hai thành phần cộng gộp:

$$T_{\text{e2e}}(L, \theta) = T_{\text{feat}}(L) + T_{\text{infer}}(\theta)$$

Trong đó, $T_{\text{feat}}(L)$ là thời gian trích xuất đặc trưng chuỗi thời gian từ cửa sổ lịch sử L giờ quá khứ, và $T_{\text{infer}}(\theta)$ là thời gian duyệt qua cấu trúc cây quyết định của mô hình LightGBM với bộ siêu tham số θ. Nếu tăng L lên 72 giờ để mô hình nhìn được nhiều quá khứ hơn, số đặc trưng tăng từ 10 lên 441, kéo theo thời gian trích xuất đặc trưng và dự báo tăng, dễ vi phạm ngưỡng 5.0 ms. Ngược lại, nếu chọn L quá ngắn và mô hình quá đơn giản, mô hình có thể bỏ lỡ diễn biến khí quyển cần cho việc phát hiện mưa dông. Đây là bài toán đánh đổi cần giải bằng **tối ưu hóa có ràng buộc**.

1.4. Mục tiêu của Bài tập lớn

Bài tập lớn thực hiện ba việc:

Phát biểu bài toán chọn cửa sổ L và siêu tham số θ thành bài toán tối ưu có ràng buộc độ trễ (Mục 2.1).
Giải bài toán bằng Optuna TPE có ràng buộc và so sánh với Random Search ở hai mức ngân sách, 40 và 100 trial/seed trên 5 seed (Mục 5).
Đánh giá nghiệm được chọn đúng một lần trên tập Test độc lập, đối chuẩn với 6 mô hình khác và kiểm tra độ trễ khi triển khai (Mục 6).

2. CƠ SỞ LÝ THUYẾT & MÔ HÌNH HÓA TOÁN HỌC

2.1. Phát biểu Bài toán Tối ưu hóa có Ràng buộc

Đề tài được hình thức hóa thành bài toán quy hoạch toán học phi tuyến có ràng buộc (Nonlinear Constrained Optimization):

$$\begin{aligned} \min_{x=(L,\theta)} \quad & f(x) = \mathrm{RMSE}_{\mathrm{val}}(L,\theta) = \sqrt{\frac{1}{|\mathcal{D}_{\mathrm{val}}|}\sum_{t\in\mathcal{D}_{\mathrm{val}}}\left(y_{t+1}-\hat{y}_{t+1}(x)\right)^2} \\ \text{thỏa mãn} \quad & g(x) = P_{95}\left(T_{\mathrm{e2e}}(x)\right) \le 5.0 \text{ ms} \quad (\text{Biên an toàn nội bộ: } \le 4.5 \text{ ms}) \\ & L \in \{1,2,3,6,12,24,36,48,72\} \text{ (giờ)} \\ & \theta \in \Theta \text{ (Không gian siêu tham số LightGBM)} \end{aligned}$$

Trong đó, $P_{95}(T_{\mathrm{e2e}})$ là phân vị thứ 95 của độ trễ suy luận đầu-cuối trên một mẫu đơn, đo qua 200 lần gọi sau 20 lần chạy khởi động. Dùng phân vị 95 thay vì trung bình để hạn chế ảnh hưởng của các lần giật xung nhịp CPU.

2.2. Thuật toán Tối ưu hóa Bayes qua Ước lượng Parzen Dạng Cây (Optuna TPE)

Thuật toán TPE (Tree-structured Parzen Estimator) của Bergstra et al. thay thế việc mô hình hóa trực tiếp hàm mục tiêu $p(y \mid x)$ bằng cách mô hình hóa hai phân phối mật độ xác suất của biến cấu hình x dựa trên một ngưỡng phân vị γ:

$$p(x \mid y) = \begin{cases} \ell(x) & \text{nếu } y < y^* \quad (\text{nhóm cấu hình tốt, chiếm tỷ lệ } \gamma) \\ g(x) & \text{nếu } y \ge y^* \quad (\text{nhóm cấu hình kém, chiếm tỷ lệ } 1-\gamma) \end{cases}$$

Độ đo kỳ vọng cải thiện (Expected Improvement - EI) được tối đa hóa thông qua tỷ số mật độ:

$$\mathrm{EI}_{y^*}(x) = \int_{-\infty}^{y^*}(y^*-y)p(y\mid x)dy = \frac{\gamma y^*\ell(x) - \ell(x)\int_{-\infty}^{y^*}P(y)dy}{\gamma\ell(x)+(1-\gamma)g(x)} \propto \left(\gamma + \frac{g(x)}{\ell(x)}(1-\gamma)\right)^{-1}$$

Điều này dẫn đến nguyên lý chọn mẫu đơn giản và hiệu quả: Điểm thử nghiệm tiếp theo x sẽ được chọn sao cho tỷ số $\frac{\ell(x)}{g(x)}$ đạt cực đại, tức là ưu tiên các vùng không gian có xác suất cao sinh ra nghiệm sai số thấp và đồng thời thỏa mãn ràng buộc thời gian trễ.

2.3. Mã hóa Góc Tuần hoàn Thời gian (Cyclical Temporal Encoding)

Để mô hình học được chu kỳ ngày/đêm (diurnal cycle) và chu kỳ mùa mưa nhiệt đới gió mùa mà không làm méo mó tính liên tục tại điểm giao thời (ví dụ: giữa 23h và 0h, giữa tháng 12 và tháng 1), bài tập lớn dùng phép biến đổi góc lượng giác sin/cos:

$$\begin{aligned} \mathrm{sin_hour} &= \sin\left(\frac{2\pi\cdot\mathrm{hour}}{24}\right), & \mathrm{cos_hour} &= \cos\left(\frac{2\pi\cdot\mathrm{hour}}{24}\right) \\ \mathrm{sin_month} &= \sin\left(\frac{2\pi\cdot\mathrm{month}}{12}\right), & \mathrm{cos_month} &= \cos\left(\frac{2\pi\cdot\mathrm{month}}{12}\right) \end{aligned}$$

2.4. Các Chỉ số Đánh giá Chất lượng Dự báo Khí tượng

Bài tập lớn dùng các độ đo sau:

Root Mean Squared Error (RMSE): Trừng phạt mạnh các sai số lớn trong các trận mưa dông cực đoan:

$$\mathrm{RMSE} = \sqrt{\frac{1}{N}\sum_{i=1}^{N}(y_i-\hat{y}_i)^2}$$

Mean Absolute Error (MAE): Đo lường sai số tuyệt đối trung bình trên toàn bộ các giờ:

$$\text{MAE} = \frac{1}{N}\sum_{i=1}^{N}|y_i - \hat{y}_i|$$

Wet Test RMSE ($y > 0$): Đo sai số độc quyền trên các giờ thực tế có mưa nhằm kiểm soát rủi ro của hiện tượng dữ liệu có quá nhiều số 0 (Zero-Inflation).
Rain Event F_1-score (≥ 0.5 mm/h): Đo năng lực phát hiện chính xác các sự kiện mưa có khả năng gây ngập:

$$F_1 = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

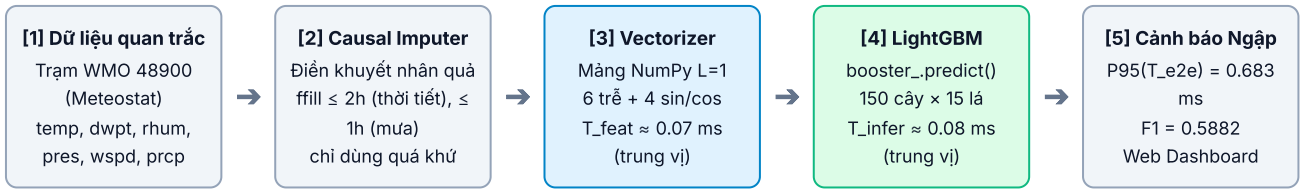
Hệ số Kỹ năng Khí tượng (Skill Score): Đo mức cải thiện tương đối của mô hình so với các phương pháp tham chiếu (Persistence hoặc Climatology):

$$\text{Skill Score} = \left(1 - \frac{\text{RMSE}_{\text{model}}}{\text{RMSE}_{\text{ref}}}\right) \times 100\%$$

3. LƯỢC ĐỒ KIẾN TRÚC & CÁCH THỨC VẬN HÀNH HỆ THỐNG

3.1. Lược đồ Luồng Dữ liệu Toàn trình (End-to-End Runtime Pipeline)

Hình 1 mô tả luồng xử lý của hệ thống, từ dữ liệu quan trắc thô của trạm Tân Sơn Nhất đến cảnh báo ngập. Bản demo hiện chạy trên dữ liệu quan trắc lịch sử, chưa nối với nguồn dữ liệu trực tiếp:



Hình 1: Luồng xử lý từ dữ liệu quan trắc đến cảnh báo ngập (bản demo chạy trên dữ liệu lịch sử)

3.2. Phân tích So sánh Kiến trúc Đệm Dữ liệu: $L = 1$ (Optuna) vs $L = 6$ (Random Search)

Hai phương pháp tối ưu chọn ra hai kiến trúc rất khác nhau:

Champion: Optuna TPE ($L = 1$) — TỐI ƯU & TINH GỌN

- **Cửa sổ lịch sử:** Đúng $L = 1$ giờ quá khứ duy nhất.
- **Số chiều đặc trưng: 10 đặc trưng** (6 biến trễ thời điểm t + 4 biến góc lượng giác sin/cos).
- **Bộ nhớ đệm chuỗi thời gian:** Chỉ lưu đúng 1 hàng quan trắc gần nhất trong RAM.
- **Thời gian trích xuất (T_{feat}):** ≈ 0.07 ms (trung vị, đường triển khai).
- **Diễn giải:** Mưa ở Tân Sơn Nhất chủ yếu là mưa dông đối lưu bùng phát nhanh; kết quả gợi ý rằng trạng thái nhiệt ẩm hiện tại cùng chu kỳ giờ trong ngày đã chứa phần lớn thông tin hữu ích cho dự báo 1 giờ tới.

Baseline: Random Search ($L = 6$) — CỒNG KỀNH

- **Cửa sổ lịch sử:** Đòi hỏi $L = 6$ giờ quá khứ liên tục.
- **Số chiều đặc trưng: 45 đặc trưng** (36 đặc trưng trễ từ lag 0 đến lag 5, 5 thống kê trượt và 4 mã hóa sin/cos).
- **Bộ nhớ đệm chuỗi thời gian:** Phải duy trì vòng đệm tròn (circular buffer) liên tục 6 giờ trong bộ nhớ.
- **Thời gian trích xuất (T_{feat}):** ≈ 0.12 ms (trung vị, chậm hơn khoảng 1.8 lần).
- **Đánh giá:** Cấu hình $L = 1$ của Optuna giúp **giảm 77.8% số chiều đặc trưng** (từ 45 xuống 10) và **giảm 83.3% số hàng bộ nhớ đệm chuỗi thời gian** (từ 6 giờ xuống 1 giờ quan trắc) so với $L = 6$ mà vẫn đạt sai số tương đương hoặc nhỉnh hơn.

4. QUY TRÌNH THU THẬP & KIỂM TOÁN CHẤT LƯỢNG DỮ LIỆU

4.1. Nguồn Dữ liệu Khí tượng Meteostat (Trạm Tân Sơn Nhất WMO 48900)

Dữ liệu khí quyển được thu thập từ trạm quan trắc quốc tế Tân Sơn Nhất (kinh độ 106.65°E, vĩ độ 10.82°N, độ cao 10m so với mực nước biển), do Meteostat lưu trữ đồng bộ từ mạng lưới trao đổi khí tượng toàn cầu (NOAA ISD / WMO). Dữ liệu thô gồm 6 biến khí quyển cơ bản: nhiệt độ không khí (`temp`), nhiệt độ điểm sương (`dwpt`), độ ẩm tương đối (`rhum`), áp suất khí quyển mực biển (`pres`), tốc độ gió (`wspd`), và lượng mưa tích lũy hàng giờ (`prcp`).

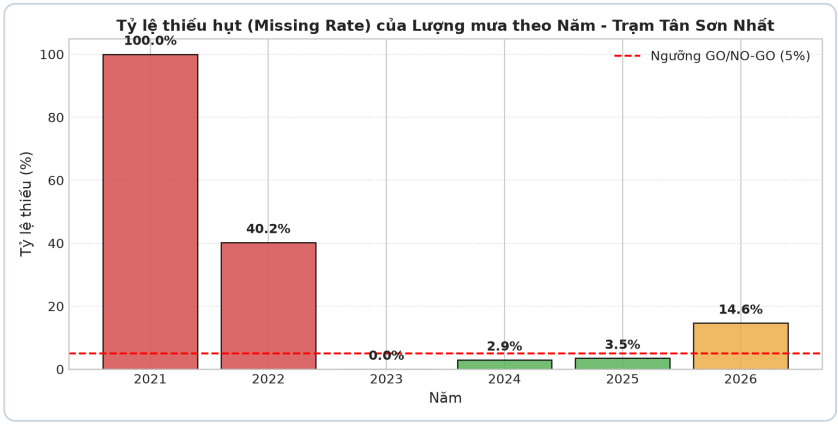
4.2. Kích hoạt Cổng Kiểm soát Chất lượng (Data Quality Gate $\leq 5\%$ Missing Rate)

Nhóm đã kiểm tra tỷ lệ thiếu dữ liệu theo từng năm từ 2021 đến 2025. Kết quả thực nghiệm bằng số liệu cụ thể (Hình 2) cho thấy:

Năm 2021: Thiếu **100.0%** dữ liệu lượng mưa (do trạm chưa tích hợp cảm biến đo mưa tự động hàng giờ).
Năm 2022: Thiếu **40.23%** dữ liệu mưa (chỉ bắt đầu ghi nhận từ nửa cuối năm 2022).

Cả hai năm này đều vi phạm nghiêm trọng ngưỡng kiểm soát chất lượng chuẩn ($> 5\%$). Nếu cố tình nội suy một chuỗi thời gian khuyết tới 40–100%, dữ liệu giả mạo sẽ làm sai lệch hoàn toàn quy luật khí quyển. Do đó, **Cổng kiểm soát dữ liệu Data Quality Gate đã loại bỏ hoàn toàn giai đoạn 2021–2022**.

Ngược lại, giai đoạn 3 năm liên tục **2023–2025** (gồm 26.304 giờ lịch) đạt chất lượng vượt trội: năm 2023 thiếu 0.00% (hoàn hảo), năm 2024 thiếu 2.93%, năm 2025 thiếu 3.47%, **trung bình toàn kỳ chỉ thiếu 2.13%** (thỏa mãn chuẩn $\leq 5\%$), được chọn làm tập dữ liệu chính thức của bài tập lớn. Ngưỡng 5% được kiểm tra tự động mỗi lần nạp dữ liệu.



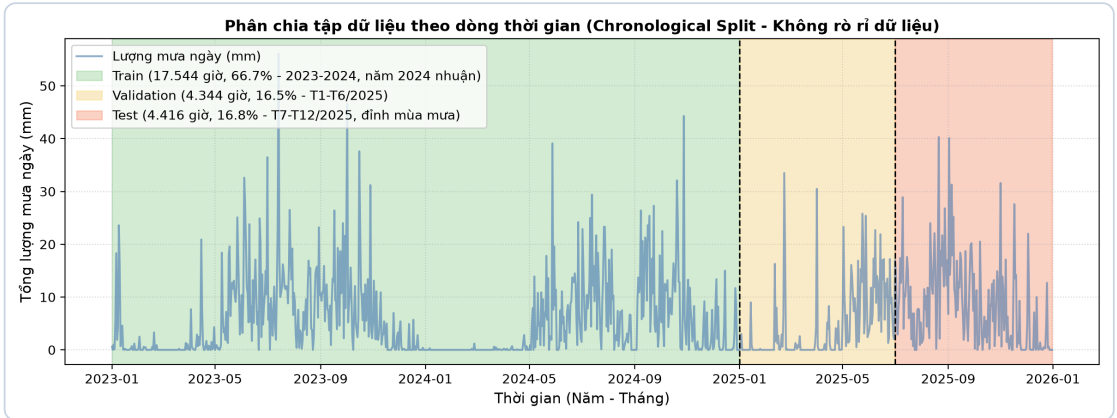
Hình 2: Kiểm toán Tỷ lệ Thiếu hụt Dữ liệu Lượng mưa theo Năm và Quyết định Kích hoạt Data Quality Gate

4.3. Điền khuyết Nhân quả (Causal Forward-Fill) và Phân chia Chuỗi Thời gian (Chronological Split)

Để tránh rò rỉ dữ liệu tương lai, mọi phép điền khuyết chỉ dùng giá trị quá khứ (**causal forward-fill**), không dùng nội suy hai chiều hay backward-fill. Năm biến thời tiết (`temp`, `dwpt`, `rhum`, `pres`, `wspd`) được điền tiến tối đa 2 giờ; lượng mưa dùng làm đặc trưng được điền tiến tối đa 1 giờ, phần còn thiếu gán 0. Nhãn mục tiêu y_{t+1} lấy nguyên từ dữ liệu gốc và không được điền: giờ nào thiếu nhãn thì bị loại khỏi tập mẫu; các dòng đầu chưa đủ L giờ lịch sử cũng bị loại.

Dữ liệu được chia theo thời gian, dựa trên thời điểm của nhãn $t + 1$ (Hình 3):

Tập Huấn luyện (Train - 66.7%): Giai đoạn 01/01/2023 – 31/12/2024 (2 năm liên tục, 17.544 giờ lịch, **17.286 mẫu mô hình hóa hiệu dụng** sau khi dropna).
Tập Thẩm định (Validation - 16.5%): Sáu tháng đầu năm 2025 (01/01/2025 – 30/06/2025, 4.344 giờ lịch, **4.057 mẫu hiệu dụng**). Dùng độc quyền để tính toán hàm mục tiêu $f(x)$ và hướng dẫn thuật toán tối ưu.
Tập Kiểm thử Độc lập (Test - 16.8%): Sáu tháng cuối năm 2025 (01/07/2025 – 31/12/2025, 4.416 giờ lịch, **4.399 mẫu hiệu dụng**). Được niêm phong hoàn toàn và chỉ mở ra đánh giá 1 lần duy nhất sau khi đã đóng băng toàn bộ siêu tham số.



Hình 3: Phân chia Tập Dữ liệu Chuỗi Thời gian Chặt chẽ theo Niên lịch (2023–2025) Triệt tiêu Rò rỉ Thông tin

5. THIẾT KẾ THỰC NGHIỆM & GIAO THỨC ĐỐI CHUẨN CÔNG BẰNG

5.1. Không gian Tìm kiếm Đồng nhất (Identical Search Space)

Optuna TPE và Random Search dùng chung đúng một không gian biến quyết định và cùng phân phối tiên nghiệm:

$L \in \{1, 2, 3, 6, 12, 24, 36, 48, 72\}$ (giờ);
`n_estimators` $\in \{20, 50, 100, 150, 200, 300\}$ (số cây);
`max_depth` $\in \{2, 3, 4, 6, 8, 10, 12\}$ (độ sâu tối đa của cây);
`num_leaves` $\in \{7, 15, 31, 63, 127\}$ (số lá tối đa của mỗi cây);
`learning_rate` $\in [0.01, 0.25]$ (lấy mẫu theo thang log-uniform);
`min_child_samples` $\in \{10, 20, 50, 100\}$ (số mẫu tối thiểu ở mỗi lá).

Đề cương dự kiến khảo sát tới 500 cây, nhưng thực nghiệm chính thức chỉ chạy tới 300 cây; mở rộng lên 400–500 cây là hướng phát triển (Mục 8).

5.2. Giao thức Đánh giá Đa Seed và Đo Độ trễ

Mỗi phương pháp được chạy lặp lại trên **5 random seed** (42, 123, 456, 789, 2026) với cùng không gian tìm kiếm. Thực nghiệm gồm hai giai đoạn:

Giai đoạn 1 (ngân sách thấp): 40 trial/seed × 5 seed = 200 trial cho mỗi phương pháp, đọc từ 40 trial đầu của mỗi lượt chạy 100 trial (TPE không biết trước tổng ngân sách nên 40 đề xuất đầu giống hệt một lượt chạy 40 trial).
Giai đoạn 2 (mở rộng ngân sách): 100 trial/seed × 5 seed = 500 trial cho mỗi phương pháp, tổng cộng 1.000 trial.

Độ trễ của mỗi trial được đo theo **giao thức pha tìm kiếm**: 20 lần gọi khởi động rồi 200 lần gọi có bấm giờ trên cửa sổ L giờ cuối của tập Validation, gồm cả trích đặc trưng (chọn cột DataFrame) và dự báo qua wrapper Scikit-learn `model.predict`. Mô hình được chọn sau đó được đo lại theo **giao thức triển khai** (trích đặc trưng NumPy và `booster_.predict`, 5 phiên × 100 lần đo), nhanh hơn đáng kể. Vì vậy ràng buộc trong pha tìm kiếm chặt hơn so với khi triển khai.

5.3. Phân loại Tham số và Siêu tham số của Hệ thống

Trong học máy cần phân biệt hai tầng tham số. **Tham số mô hình** (model parameters) là các đại lượng thuật toán huấn luyện tự học từ dữ liệu. **Siêu tham số** (hyperparameters) nằm ngoài quá trình học và quyết định cấu trúc hoặc cách huấn luyện mô hình; siêu tham số được chia tiếp thành ba nhóm: của mô hình, của quá trình huấn luyện và của pipeline. Bảng 1–4 liệt kê toàn bộ các nhóm này cho mô hình champion; Bảng 5–6 liệt kê thiết lập của bài toán tối ưu và của khâu đánh giá. Cột "Ai/điều gì quyết định" ghi rõ giá trị do thuật toán huấn luyện học, do Optuna TPE tìm (HPO) hay do người thiết kế cố định.

THAM SỐ	SỐ LƯỢNG TRONG MÔ HÌNH	Ý NGHĨA	AI/ĐIỀU GÌ QUYẾT ĐỊNH
Đặc trưng dùng để tách tại mỗi nút	2.100 nút (150 cây × 14 nút)	Chọn biến để chia nhánh; dùng nhiều nhất là lượng mưa giờ hiện tại `prcp_lag_0` (558 lần), rồi áp suất `pres_lag_0` (260 lần)	Thuật toán huấn luyện LightGBM: chọn phép tách làm giảm sai số bình phương nhiều nhất (gain) trên tập Train
Ngưỡng tách tại mỗi nút	2.100 ngưỡng (156 cặp đặc trưng–ngưỡng khác nhau)	Giá trị so sánh tại nút, ví dụ "`prcp_lag_0` ≤ ngưỡng"	Thuật toán huấn luyện, tìm trên histogram tối đa 255 bin của mỗi đặc trưng
Giá trị đầu ra tại mỗi lá	2.250 giá trị (150 cây × 15 lá)	Lượng mưa (mm) cộng dồn vào dự báo khi mẫu rơi vào lá đó	Tính từ gradient của sai số bình phương trên tập Train, nhân với `learning_rate`
Trọng số w và hệ số chặn b (Linear/Ridge, $L = 6$)	45 trọng số + 1 hệ số chặn	Mô hình đối chứng tuyến tính	Bình phương tối thiểu (OLS), Ridge thêm phạt L2; học trên tập Train
Bảng trung bình tháng–giờ (Climatology)	288 giá trị (12 tháng × 24 giờ)	Mô hình đối chứng khí hậu	Trung bình lượng mưa theo tháng và giờ trên tập Train
Persistence	Không có tham số học	$\hat{y}_{t+1} = y_t$	Quy tắc cố định

Bảng 1: Tham số mô hình (model parameters), học từ dữ liệu trong quá trình huấn luyện

SIÊU THAM SỐ	GIÁ TRỊ (CHAMPION)	MIỀN / CÁCH ĐẶT	AI/ĐIỀU GÌ QUYẾT ĐỊNH
Họ mô hình	LightGBM, cây tăng cường gradient (`boosting_type = gbdt`)	Chọn trước khi tối ưu	Người thiết kế
`n_estimators` (số cây)	150	$\{20, 50, 100, 150, 200, 300\}$	HPO (Optuna TPE)
`max_depth` (độ sâu tối đa)	12	$\{2, 3, 4, 6, 8, 10, 12\}$	HPO (Optuna TPE)
`num_leaves` (số lá tối đa mỗi cây)	15	$\{7, 15, 31, 63, 127\}$	HPO (Optuna TPE)
`min_child_samples` (số mẫu tối thiểu ở một lá)	20	$\{10, 20, 50, 100\}$	HPO (Optuna TPE)
`min_child_weight`	0.001	Cố định (mặc định LightGBM)	Người thiết kế
`min_split_gain`	0	Cố định (mặc định LightGBM)	Người thiết kế

Bảng 2: Siêu tham số của mô hình (cấu trúc và dung lượng của cây). Với `num_leaves` = 15, `max_depth` = 12 chỉ là trần độ sâu: LightGBM phát triển cây theo lá, mỗi cây của champion có đúng 15 lá.

SIÊU THAM SỐ	GIÁ TRỊ (CHAMPION)	MIỀN / CÁCH ĐẶT	AI/ĐIỀU GÌ QUYẾT ĐỊNH
`learning_rate` (tốc độ học, shrinkage)	0.0215	$[0.01, 0.25]$, log-uniform	HPO (Optuna TPE)
Hàm mất mát (`objective`)	Sai số bình phương (regression L2)	Cố định, khớp với mục tiêu RMSE	Người thiết kế
`reg_alpha` / `reg_lambda` (phạt L1/L2, tương tự weight decay)	0 / 0	Cố định (mặc định), không điều chuẩn	Người thiết kế
`subsample` / `subsample_freq` (bagging)	1.0 / 0	Cố định: mỗi vòng dùng toàn bộ 17.286 mẫu Train (GBDT không có batch size như mạng nơ-ron)	Người thiết kế
`colsample_bytree`	1.0	Cố định: mỗi cây dùng mọi đặc trưng	Người thiết kế
`max_bin` / `subsample_for_bin`	255 / 200.000	Cố định (mặc định): số bin histogram khi tìm ngưỡng tách	Người thiết kế
Early stopping	Không dùng	Huấn luyện đủ `n_estimators` vòng	Người thiết kế
`random_state`	42 (champion); bằng seed của lượt chạy khi tìm kiếm	Không ảnh hưởng kết quả vì không dùng bagging hay lấy mẫu đặc trưng	Người thiết kế
`n_jobs`	1	Chạy đơn luồng để đo độ trễ ổn định	Người thiết kế

Bảng 3: Siêu tham số của quá trình huấn luyện

SIÊU THAM SỐ	GIÁ TRỊ (CHAMPION)	MIỀN / CÁCH ĐẶT	AI/ĐIỀU GÌ QUYẾT ĐỊNH
Cửa sổ lịch sử L (giờ)	1	$\{1, 2, 3, 6, 12, 24, 36, 48, 72\}$	HPO (Optuna TPE), là biến quyết định cùng với θ
Biến đầu vào	6 biến: `temp`, `dwpt`, `rhum`, `pres`, `wspd`, `prcp`	Cố định	Người thiết kế
Đặc trưng trễ	6 (lag 0)	$6 \times L$ đặc trưng, từ lag 0 đến lag $L - 1$	Pipeline, suy ra từ L
Thống kê trượt	Không dùng (vì $L = 1$)	5 đặc trưng khi $L \geq 3$: trung bình, max, độ lệch chuẩn của mưa; trung bình nhiệt độ và độ ẩm	Người thiết kế; bật/tắt theo L
Mã hóa chu kỳ	4: sin/cos giờ (chu kỳ 24), sin/cos tháng (chu kỳ 12)	Cố định	Người thiết kế
Tổng số đặc trưng	10	$6L + 4$, thêm 5 khi $L \geq 3$ ($L = 72$ cho 441 đặc trưng)	Pipeline, suy ra từ L
Chuẩn hóa thang đo (scaler)	Không dùng	Mô hình cây không phụ thuộc thang đo của đặc trưng	Người thiết kế
Điền khuyết biến thời tiết	Điền tiến tối đa 2 giờ	Cố định, chỉ dùng quá khứ	Người thiết kế
Điền khuyết lượng mưa (đặc trưng)	Điền tiến tối đa 1 giờ, còn thiếu gán 0	Cố định, chỉ dùng quá khứ	Người thiết kế
Nhãn mục tiêu	y_{t+1} (tầm dự báo 1 giờ), không điền	Giờ thiếu nhãn bị loại khỏi tập mẫu	Người thiết kế
Cổng chất lượng dữ liệu	Tỷ lệ thiếu mưa mỗi năm $\leq 5\%$, dùng giai đoạn 2023–2025	Cố định, kiểm tra tự động mỗi lần nạp dữ liệu	Người thiết kế
Mốc chia tập (theo thời điểm nhãn)	Train ≤ 31/12/2024; Validation 01/01–30/06/2025; Test 01/07–31/12/2025	Cố định	Người thiết kế

Bảng 4: Siêu tham số của pipeline dữ liệu và đặc trưng

THIẾT LẬP	GIÁ TRỊ
Hàm mục tiêu	RMSE trên tập Validation
Ràng buộc	$P_{95}(T_{\text{e2e}}) \leq 5.0$ ms; biên an toàn nội bộ 4.5 ms
Đo độ trễ khi tìm kiếm	Giao thức pha tìm kiếm: 20 lần khởi động + 200 lần đo, trên L giờ cuối của tập Validation
Ngân sách	100 trial/seed × 5 seed cho mỗi phương pháp; giai đoạn 1 là 40 trial đầu của mỗi seed
Seed	42, 123, 456, 789, 2026
Optuna TPE	`TPESampler(seed, constraints_func)`, hướng cực tiểu; 10 trial khởi đầu lấy mẫu ngẫu nhiên, 24 ứng viên EI, chế độ đa biến (mặc định của Optuna 5.0.0)
Random Search	Lấy mẫu đều; `learning_rate` lấy log-uniform rồi làm tròn 4 chữ số; seed sinh cấu hình = seed × 1000 + số thứ tự trial
Quy tắc chọn nghiệm	Val RMSE nhỏ nhất trong các trial thỏa ràng buộc

Bảng 5: Thiết lập của bài toán tối ưu siêu tham số (HPO)

THIẾT LẬP	GIÁ TRỊ
Đánh giá trên tập Test	Một lần duy nhất, sau khi đã chốt toàn bộ siêu tham số
Ngưỡng sự kiện mưa (cho F_1)	$\geq 0.5\ \mathrm{mm/h}$, áp dụng cho cả giá trị thật và giá trị dự báo
Wet RMSE	Chỉ tính trên các giờ có mưa thật ($y > 0$)
Mô hình tham chiếu cho Skill Score	Persistence và Climatology (trung bình tháng–giờ trên tập Train)
Đo độ trễ khi triển khai	Giao thức triển khai: trích đặc trưng NumPy + `booster_.predict`, 5 phiên × 100 lần đo (mỗi phiên 20 lần khởi động), lấy trung vị của P_{95}
Ngưỡng cảnh báo ngập (dashboard)	Đỏ ≥ 10; cam ≥ 3; vàng $\geq 0.5\ \mathrm{mm/h}$; dưới 0.5 mm/h là bình thường (bản demo dòng lệnh dùng 3 mức, không có mức cam)

Bảng 6: Thiết lập đánh giá và triển khai

> **Câu hỏi tự kiểm tra:** `n_estimators` và `max_depth` là parameter hay hyperparameter? Còn các ngưỡng tách thực tế trong từng cây được xác định như thế nào?
> **Trả lời (áp dụng cho bài tập lớn):** `n_estimators` và `max_depth` là *siêu tham số* vì được chọn trước khi huấn luyện; ở đây chúng do Optuna TPE chọn (150 cây, độ sâu tối đa 12). Còn ngưỡng tách và đặc trưng tại mỗi nút là *tham số mô hình*: khi xây từng cây, LightGBM gom giá trị của mỗi đặc trưng thành tối đa 255 bin, rồi ở mỗi bước chọn lá và cặp (đặc trưng, ngưỡng) làm giảm sai số bình phương nhiều nhất trên tập Train. Mô hình champion học được 2.100 ngưỡng tách như vậy. Random Forest cũng tương tự: số cây và độ sâu là siêu tham số, ngưỡng tách do thuật toán học từ dữ liệu.

6. KẾT QUẢ THỰC NGHIỆM & THẢO LUẬN

6.1. Bảng Đối chuẩn Đa Mô hình (Multi-Model Benchmark)

Bảng 7 đối chuẩn 7 mô hình trên tập Validation và tập Test, gồm các chỉ số sai số, độ trễ triển khai và hệ số kỹ năng (Skill Score) so với Persistence và Climatology. Số liệu lấy trực tiếp từ `results/multi_model_benchmark.csv`; tập Test chỉ được đánh giá một lần.

STT	MÔ HÌNH	L	SỐ ĐẶC TRƯNG	CẤU HÌNH	VAL RMSE	TEST RMSE	TEST MAE	WET RMSE	RAIN F_1	TRỄ P_{95} (MS)	SKILL VS PERS.	SKILL VS CLIM.
1	**Persistence (ngây thơ)**	1	1	$\hat{y}_{t+1} = y_t$	1.0699	1.5674	0.4543	3.0420	0.5570	0.05*	+0.00%	-26.81%
2	**Climatology (tháng–giờ)**	1	2	$\mathbb{E}[y \mid \text{tháng, giờ}]$	0.8615	1.2360	0.4615	2.3431	0.4580	0.08*	+21.14%	+0.00%
3	**Linear Regression**	6	45	OLS	0.8468	1.2203	0.4712	2.3411	0.5112	0.921	+22.14%	+1.27%
4	**Ridge Regression**	6	45	$\alpha = 1.0$	0.8467	1.2203	0.4713	2.3411	0.5112	1.074	+22.14%	+1.27%
5	**LightGBM mặc định**	6	45	100 cây, depth −1	0.8499	1.2036	0.4021	2.3136	0.5617	0.959	+23.21%	+2.62%
6	**Random Search tốt nhất**	6	45	200 cây, depth 12, lr 0.0171	0.8290	1.1891	0.3993	2.2937	0.5778	0.936	+24.14%	+3.79%
7	**Optuna TPE (champion)**	**1**	**10**	**150 cây, depth 12, 15 lá, lr 0.0215**	**0.8318**	**1.1774**	**0.3998**	**2.2735**	**0.5882**	**0.683**	**+24.88%**	**+4.74%**

Bảng 7: Đối chuẩn 7 mô hình trên tập Test độc lập H2/2025. Mọi mô hình đều thỏa ràng buộc 5.0 ms; (*) độ trễ của Persistence và Climatology là giá trị danh nghĩa, không phải số đo.

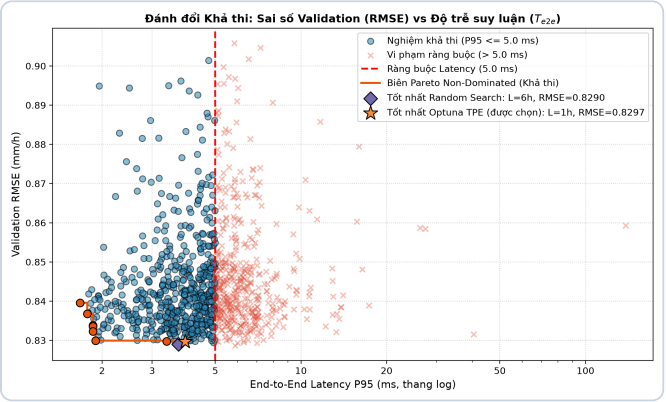
Để kiểm tra các chênh lệch trên tập Test có ổn định không, nhóm lấy mẫu lại theo khối ngày (185 ngày, 4.000 lần) và tính khoảng tin cậy 95% cho hiệu RMSE giữa champion và từng mô hình. Mức giảm sai số so với Persistence (-0.390), Climatology (-0.059), Linear Regression (-0.043) và LightGBM mặc định ($-0.026\ \mathrm{mm/h}$) đều có khoảng tin cậy nằm hẳn dưới 0. So với mô hình của Random Search, hiệu là $-0.012\ \mathrm{mm/h}$ (khoảng 1%) với khoảng tin cậy $[-0.024;\ +0.0004]$ chạm 0, nên chỉ có thể xem hai mô hình là tương đương về độ chính xác.

6.2. So sánh Tỷ lệ Khả thi và Độ Ổn định của Hai Phương pháp Tối ưu

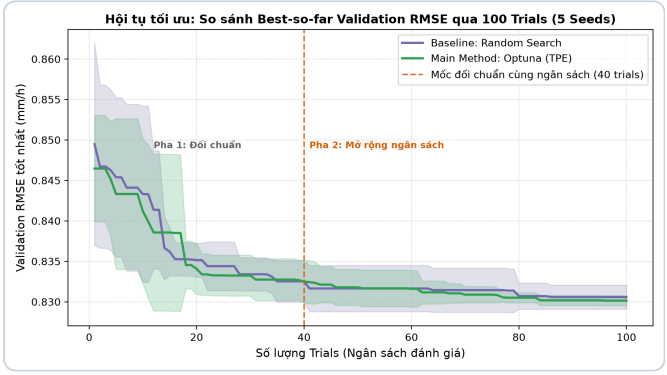
Bảng 8 tổng hợp kết quả từ 1.000 trial trong hai file nhật ký `results/optimization_history_optuna.csv` và `results/optimization_history_random.csv`:

TIÊU CHÍ	RANDOM SEARCH	OPTUNA TPE	CHÊNH LỆCH / KIỂM ĐỊNH
Tổng số trial	500 (5 seed)	500 (5 seed)	Cùng ngân sách 100 trial/seed
Số trial khả thi ($P_{95} \le 5.0$ ms)	243 / 500 (48.6%)	**312 / 500 (62.4%)**	+13.8 điểm phần trăm
Số trial khả thi ($P_{95} \le 4.5$ ms)	165 / 500 (33.0%)	**251 / 500 (50.2%)**	+17.2 điểm phần trăm
Khả thi ở giai đoạn 1 (40 trial/seed)	78 / 200 (39.0%)	**118 / 200 (59.0%)**	+20.0 điểm phần trăm
Khả thi theo từng seed (42 / 123 / 456 / 789 / 2026)	26 / 42 / 48 / 66 / 61	66 / 53 / 69 / 71 / 53	TPE dẫn 4/5 seed; Wilcoxon $p = 0.1875$, t cặp $p = 0.162$ (chưa có ý nghĩa thống kê)
Kiểm định Fisher gộp 1.000 trial	—	—	$p = 1.47 \times 10^{-5}$, OR = 1.76; giả định các trial độc lập, không đúng với TPE
Val RMSE tốt nhất trong nhật ký	**0.8290** (seed 2026)	0.8297 (seed 456)	Chênh lệch 0.0007 mm/h
Val RMSE khi huấn luyện lại	**0.8290**	0.8318	Nhật ký Optuna cũ làm tròn `learning_rate` 4 chữ số nên huấn luyện lại lệch nhẹ
Val RMSE tốt nhất của từng seed (trung bình ± độ lệch chuẩn)	0.8306 ± 0.0017	0.8301 ± 0.0007	t cặp: $t = 0.4527$, $p = 0.6742$ (không bác bỏ H_0); độ lệch chuẩn giảm 57.6%
Cửa sổ được chọn	$L = 6$ (45 đặc trưng)	$L = 1$ **(10 đặc trưng)**	Giảm 77.8% số đặc trưng và 83.3% số hàng đệm
Độ trễ triển khai P_{95} của nghiệm được chọn	0.936 ms	**0.683 ms** [0.66; 0.75]	Cả hai thỏa 5.0 ms và biên an toàn 4.5 ms

Bảng 8: So sánh Optuna TPE và Random Search qua 5 seed (số liệu từ `results/final_test_metrics.json`)



Hình 4: Val RMSE theo P_{95} pha tìm kiếm của 1.000 trial, kèm biên Pareto khả thi



Hình 5: Val RMSE tốt nhất theo số trial (trung bình ± độ lệch chuẩn qua 5 seed)

6.3. Thảo luận về Kiểm định Thống kê và Ràng buộc Độ trễ

Từ Bảng 7, Bảng 8 và Hình 4, 5, nhóm rút ra các nhận xét sau:

Về sai số: hai phương pháp cho Val RMSE tốt nhất tương đương (kiểm định t cặp trên 5 seed: $t = 0.4527$, $p = 0.6742$). Bề mặt hàm mục tiêu quanh vùng tối ưu khá phẳng: nhiều cấu hình khác nhau ($L = 1, 36, 48$ với các `max_depth` khác nhau) cho Val RMSE trong khoảng 0.8297–0.8318 mm/h. Trên tập Test, champion của TPE nhỉnh hơn mô hình của Random Search khoảng 1%, nhưng khoảng tin cậy chạm 0 (Mục 6.1).
Về tỷ lệ khả thi: TPE có nhiều cấu hình thỏa ràng buộc hơn (+13.8 điểm phần trăm ở 5.0 ms, +20.0 điểm ở giai đoạn 1). Tuy nhiên, tính theo đúng đơn vị lặp lại là seed thì chênh lệch chưa có ý nghĩa thống kê (Wilcoxon $p = 0.1875$; với 5 seed, kiểm định hai phía không thể cho $p < 0.0625$). Kiểm định Fisher gộp cho $p = 1.47 \times 10^{-5}$ nhưng giả định các trial độc lập, trong khi TPE đề xuất trial sau dựa trên các trial trước.
Nguồn gốc chênh lệch khả thi: cửa sổ L ảnh hưởng thật đến độ trễ (Random Search khả thi 86.8% ở $L = 1$ nhưng chỉ 24.6% ở $L = 72$), và TPE dồn 45.0% số trial vào $L \in \{1, 2\}$ so với 22.8% của Random Search. Áp tỷ lệ khả thi theo từng L của Random Search lên phân bố L của TPE cho 57.5%, tức khoảng 8.9 trong 13.8 điểm phần trăm chênh lệch đến từ việc TPE học được rằng cửa sổ ngắn chạy nhanh hơn.
Nhiễu đo độ trễ trong pha tìm kiếm: với một mẫu đơn, chi phí duyệt tối đa 300 cây chỉ cỡ micro-giây, nhỏ hơn nhiều so với overhead cố định của wrapper; trong nhật ký, P_{95} gần như không tương quan với số cây (hệ số Spearman ≈ 0.01). Trung vị P_{95} của từng khối 20 trial liên tiếp trong cùng một seed dao động từ 2.07 đến 6.75 ms, cho thấy trạng thái máy theo thời gian ảnh hưởng đáng kể đến cờ khả thi. Vì hai phương pháp chạy ở hai thời điểm khác nhau, phần chênh lệch còn lại (khoảng 4.9 điểm phần trăm) không tách được khỏi điều kiện máy.
Hai thang đo độ trễ: pha tìm kiếm đo qua wrapper Scikit-learn, trung vị P_{95} là 4.49 ms (Optuna) và 5.04 ms (Random Search); ràng buộc 5.0 ms loại 37.6% trial của Optuna và 51.4% trial của Random Search. Khi triển khai, champion gọi `booster_.predict` trên mảng NumPy và đạt $P_{95} = 0.683$ ms, còn dư khoảng 3.8 ms so với biên an toàn 4.5 ms.
Ổn định qua các seed: độ lệch chuẩn của Val RMSE tốt nhất qua 5 seed giảm từ 0.0017 (Random Search) xuống 0.0007 (TPE), tức giảm 57.6%; đây là quan sát trên 5 seed, chưa được kiểm định.

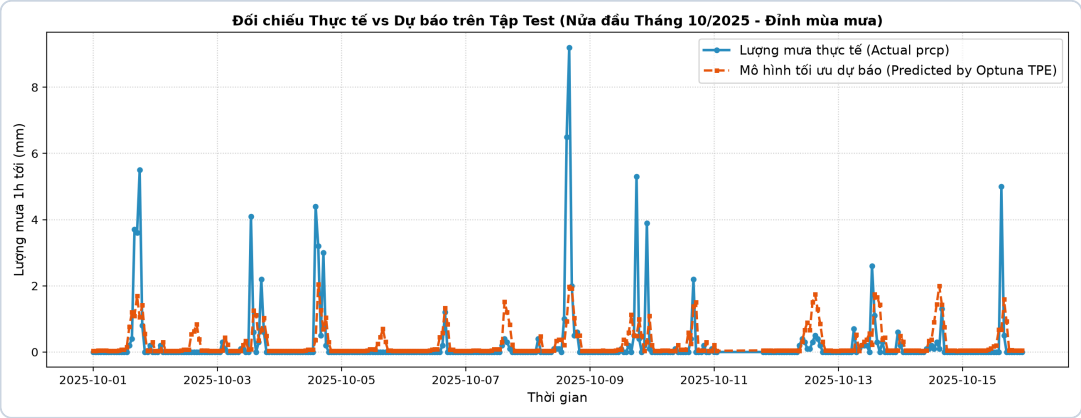
6.4. Giải mã Hiện tượng Chuyển dịch Phân phối Mùa Khí hậu (Seasonal Shift)

Một câu hỏi quan trọng: *Tại sao Train RMSE là 0.8243 mm/h, Val RMSE là 0.8318 mm/h nhưng sang tập Test lại tăng lên 1.1774 mm/h? Mô hình có bị quá khớp (overfitting) không?*

Câu trả lời là: **mô hình không có dấu hiệu quá khớp**, vì khoảng cách Train–Val rất nhỏ (chỉ $+0.0075$ mm/h). Sự gia tăng sai số ở tập Test xuất phát từ bản chất vật lý khí quyển (Hình 6):

Tập Validation (H1/2025 - Sáu tháng đầu năm): Gồm mùa khô và giai đoạn chuyển mùa; lượng mưa ít, độ lệch chuẩn lượng mưa chỉ là $\sigma_{\text{val}} = 0.93$ mm/h.
Tập Test (H2/2025 - Sáu tháng cuối năm): Rơi vào **cao điểm mùa mưa Tây Nam tại Nam Bộ** với độ lệch chuẩn lượng mưa tăng vọt lên $\sigma_{\text{test}} = 1.33$ mm/h **(+42.6%)**, tỷ lệ giờ có mưa tăng từ 15.23% lên 25.82% và có các trận mưa dông lớn (tối đa 23.4 mm/h).

Khi độ lệch chuẩn của lượng mưa tăng hơn 40%, sai số tuyệt đối tăng theo là điều dễ hiểu; mức tăng sai số trên Test chủ yếu phản ánh sự dịch chuyển phân phối theo mùa chứ không phải quá khớp.



Hình 6: Đối chiếu Lượng mưa Thực tế vs Dự báo của Champion Model trên Tập Test Độc lập H2/2025

7. ĐẢM BẢO CHẤT LƯỢNG KỸ THUẬT PHẦN MỀM (MLOPS & VERIFICATION)

7.1. Kiểm thử Tính tương đương giữa Huấn luyện và Triển khai (Parity Test)

Lỗi dễ gặp trong hệ thống học máy là đặc trưng lúc huấn luyện (tạo theo lô bằng Pandas) khác với đặc trưng lúc triển khai (tạo cho một mẫu bằng NumPy). Nhóm viết ca kiểm thử `test_feature_parity_batch_vs_single_sample` trong `tests/test_pipeline.py`:

So khớp vector đặc trưng của hai đường xử lý tại $L \in \{1, 6, 24, 72\}$, 10 mẫu ngẫu nhiên cho mỗi L: sai lệch không vượt quá 10^{-5};
So khớp dự báo của mô hình champion trên 25 mẫu ngẫu nhiên: chênh lệch dưới 10^{-5} mm/h.

7.2. Tích hợp Liên tục (CI) trên GitHub Actions với Python 3.13

Repository có quy trình CI (`.github/workflows/ci.yml`) chạy trên Ubuntu với Python 3.13. Mỗi lần push hoặc mở pull request vào nhánh `main`, CI cài thư viện, tải dữ liệu Meteostat, chạy toàn bộ kiểm thử tự động (12 ca kiểm thử, đều đạt khi chạy cục bộ) và chạy thử demo suy luận. Các ca kiểm thử gồm cả kiểm tra không gian tìm kiếm trong mã nguồn khớp với nhật ký thực nghiệm và kiểm tra cổng chất lượng dữ liệu.

7.3. Triển khai Ứng dụng Web Dashboard Tương tác Trực quan

Nhóm đã xây dựng một Web Application hoàn chỉnh (`src/server.py` và thư mục `web/`), cung cấp giao diện trực quan tại `http://127.0.0.1:8000`, hỗ trợ:

Mô phỏng thời tiết tức thời (Nhiệt độ, Độ ẩm, Áp suất, Mưa giờ trước);
Đo đạc độ trễ phần cứng thực tế (Hardware Latency Benchmark qua $N = 200$ lần chạy);
Xem bảng đối chuẩn 7 mô hình và phát cảnh báo ngập theo 4 mức (bình thường, vàng ≥ 0.5, cam ≥ 3, đỏ ≥ 10 mm/h).

8. HẠN CHẾ & HƯỚNG PHÁT TRIỂN

Bài tập lớn còn các hạn chế sau:

Nhiễu đo độ trễ và số seed: cờ khả thi trong pha tìm kiếm chịu ảnh hưởng của trạng thái máy theo thời gian (Mục 6.3), và 5 seed chưa đủ để kiểm định theo seed đạt $p < 0.05$. Lần chạy tiếp theo nên dùng ít nhất 6 seed (khuyến nghị 10), cho hai phương pháp chạy xen kẽ trên cùng điều kiện máy và đo lặp mỗi cấu hình.
Không gian tìm kiếm: đề cương dự kiến tới 500 cây nhưng thực nghiệm chính thức dừng ở 300 cây. Có thể mở rộng lên 400–500 cây và đưa thêm các siêu tham số đang cố định (Bảng 3) như `reg_lambda`, `subsample`, `colsample_bytree` vào không gian tìm kiếm.
Độ lệch mẫu theo L: mỗi L cần L giờ lịch sử nên số mẫu Train chênh nhau chút ít giữa các L (17.286 mẫu ở $L = 1$ và 17.215 mẫu ở $L = 72$). Có thể cắt cố định 72 dòng đầu cho mọi cấu hình để tập mẫu hoàn toàn đồng nhất.
Kiểm định chéo theo thời gian: hiện chỉ dùng một phân chia cố định (Train 2023–2024, Validation H1/2025, Test H2/2025). Có thể dùng rolling-origin cross-validation qua nhiều năm để đánh giá độ ổn định dài hạn.
Trạm đơn và dữ liệu lịch sử: dữ liệu chỉ lấy từ trạm Tân Sơn Nhất và hệ thống chưa nối với nguồn dữ liệu trực tiếp; mở rộng sang các trạm lân cận và xây đường dữ liệu thời gian thực là bước tiếp theo.

9. KẾT LUẬN

Bài tập lớn đã phát biểu và giải bài toán chọn cửa sổ lịch sử và siêu tham số cho mô hình dự báo lượng mưa 1 giờ tới dưới ràng buộc độ trễ suy luận. Các kết quả chính:

Mô hình hóa tối ưu có ràng buộc: cực tiểu Val RMSE theo (L, θ) với ràng buộc $P_{95}(T_{\text{e2e}}) \leq 5.0$ ms (biên an toàn 4.5 ms), giải bằng Optuna TPE có ràng buộc và so sánh với Random Search trên 1.000 trial.
So sánh hai phương pháp tối ưu: Val RMSE tốt nhất tương đương; TPE có tỷ lệ cấu hình khả thi cao hơn (62.4% so với 48.6%) và ổn định hơn qua các seed, nhưng chênh lệch khả thi chưa có ý nghĩa thống kê theo seed và một phần lẫn với nhiễu đo.
Nghiệm gọn: TPE chọn $L = 1$ (10 đặc trưng, ít hơn 77.8% so với 45 đặc trưng của Random Search), đạt Test RMSE 1.1774 mm/h và $F_1 = 0.5882$, giảm 24.9% sai số so với Persistence và 4.7% so với Climatology, với độ trễ triển khai $P_{95} = 0.683$ ms.
Tái lập: mã nguồn mở, 12 ca kiểm thử tự động đều đạt, kèm Web Dashboard minh họa.

TÀI LIỆU THAM KHẢO

[1] J. Bergstra, R. Bardenet, Y. Bengio, and B. Kégl, "Algorithms for hyper-parameter optimization," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 24, 2011.

[2] T. Akiba, S. Sano, T. Yanase, T. Ohta, and M. Koyama, "Optuna: A next-generation hyperparameter optimization framework," in *Proc. ACM SIGKDD Int. Conf. Knowl. Discov. Data Min.*, 2019, pp. 2623–2631.

[3] G. Ke, Q. Meng, T. Finley, T. Wang, W. Chen, W. Ma, Q. Ye, and T.-Y. Liu, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 30, 2017.

[4] Meteostat Open Weather and Climate Data, "Hourly weather data for weather station Tan Son Nhat (ID: 48900)," *Meteostat Python Package*, 2026. [Online]. Available: https://meteostat.net/.

[5] F. Pedregosa et al., "Scikit-learn: Machine learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, 2011.