TRƯỜNG ĐẠI HỌC VĂN LANG — KHOA CÔNG NGHỆ THÔNG TIN
BỘ MÔN TRÍ TUỆ NHÂN TẠO | HỌC PHẦN: NHẬP MÔN TỐI ƯU HÓA

BÁO CÁO THUYẾT MINH ĐỒ ÁN CHUYÊN SÂU (PROJECT PROPOSAL)

TỐI ƯU HÓA DỰ BÁO LƯỢNG MƯA THEO GIỜ DƯỚI RÀNG BUỘC ĐỘ TRỄ SUY LUẬN PHẦN CỨNG

Mô hình hóa bài toán tối ưu có ràng buộc thời gian thực, triệt tiêu rò rỉ dữ liệu, giải quyết nút thắt kỹ thuật luồng dữ liệu và đối chuẩn đa phương pháp trên trạm quan trắc Tân Sơn Nhất (WMO ID: 48900)

SINH VIÊN THỰC HIỆN
Trần An Kỳ (Chuyên ngành Trí tuệ Nhân tạo - AI)

GIẢNG VIÊN HƯỚNG DẪN
Giảng viên Bộ môn Trí tuệ Nhân tạo

ĐỐI TƯỢNG & ĐỊA BÀN NGHIÊN CỨU
Lượng mưa giờ kế tiếp (y_{t+1}) trạm Tân Sơn Nhất (48900)

RÀNG BUỘC PHẦN CỨNG MỤC TIÊU
Độ trễ toàn trình $T_{e2e} \leq 5.0$ ms trên CPU đơn luồng

1. Bối cảnh Thực tiễn & Câu hỏi Nghiên cứu Cốt lõi

1.1. Hiện trạng ngập lụt đô thị TP. Hồ Chí Minh: Ngập lụt do mưa lớn cực đoan xảy ra với tần suất ngày càng dày đặc tại các đô thị lớn như TP. Hồ Chí Minh. Các trận mưa dông nhiệt đới cục bộ thường phát triển rất nhanh, trút xuống hàng chục milimét nước chỉ trong vòng 1 giờ, gây quá tải hoàn toàn hệ thống thoát nước đô thị và làm tê liệt giao thông. Để chủ động ứng phó, các hệ thống hỗ trợ vận hành máy bơm và đóng/mở cống ngăn triều đòi hỏi phải có dự báo lượng mưa trước 1 giờ (y_{t+1}).

1.2. Thách thức Ràng buộc Thời gian thực (Hardware Latency Constraint): Một mô hình dự báo dù có độ chính xác cao trên lý thuyết nhưng nếu tốn hàng trăm mili-giây hoặc hàng giây để suy luận thì không thể triển khai trên các thiết bị máy tính nhúng tại trạm quan trắc cạnh (Edge IoT) hoặc phục vụ vòng quét tự động thời gian thực hàng trăm điểm đo. Vì vậy, độ chính xác bắt buộc phải đi kèm với **ràng buộc thời gian suy luận nghiêm ngặt**.

> **Câu hỏi Nghiên cứu Then chốt của Đồ án:**
> *"Với giới hạn độ trễ suy luận toàn trình không vượt quá **5.0 ms** trên CPU đơn lõi, nên sử dụng bao nhiêu giờ lịch sử quan trắc (L) và cấu hình siêu tham số mô hình nào (θ) để sai số dự báo lượng mưa giờ kế tiếp là nhỏ nhất?"*

2. Mô hình hóa Toán học Bài toán Tối ưu có Ràng buộc

Bài toán được chuẩn hóa chặt chẽ theo dạng bài toán tối ưu có ràng buộc phần cứng (Constrained Hyperparameter & Feature Optimization):

Cực tiểu hóa:	$f(x) = \mathrm{RMSE}_{\mathrm{val}}(L, \theta)$ (Sai số RMSE trên tập thẩm định)
Biến quyết định:	$x = (L, \theta)$ gồm cửa sổ lịch sử L và vector siêu tham số θ
Ràng buộc độ trễ:	$T_{\mathrm{e2e}}(L, \theta) = T_{\mathrm{transform}}(L) + T_{\mathrm{predict}}(\theta) \leq 5.0\ \mathrm{ms}$
Miền cửa sổ:	$L \in (1, 2, 3, 6, 12, 24, 36, 48, 72)$ (Số giờ lịch sử quan sát)
Miền siêu tham số:	$\theta \in \Theta$ (Không gian 5 siêu tham số LightGBM)

2.1. Chi tiết Biến quyết định (Decision Variables $x = (L, \theta)$)

- **Độ dài cửa sổ lịch sử (L):** Số giờ quá khứ dùng để trích xuất đặc trưng trễ (lags) và thống kê trượt (rolling mean, max, std). Càng tăng L, mô hình càng có nhiều thông tin quá khứ nhưng làm tăng số chiều đặc trưng và tốn thời gian tiền xử lý.
- **Siêu tham số mô hình (θ):** Gồm 5 siêu tham số then chốt của LightGBM:
  - `max_depth` $\in$ [2, 12] (Độ sâu tối đa của cây quyết định)
  - `n_estimators` $\in$ [20, 300] (Số lượng cây tăng cường)
  - `num_leaves` $\in$ [7, 127] (Số lượng lá trên cây)
  - `learning_rate` $\in$ [0.01, 0.25] (Tốc độ học, lấy mẫu phân phối log-uniform)
  - `min_child_samples` $\in$ [10, 100] (Số mẫu tối thiểu trên mỗi lá để chống quá khớp)

2.2. Giao thức Đo lường Ràng buộc End-to-End Latency ($T_{\mathrm{e2e}} \leq 5.0$ ms)

Độ trễ được đo lường trực tiếp trên **suy luận đơn mẫu (single-sample inference)** mô phỏng đúng lúc trạm quan trắc nhận dữ liệu của giờ hiện tại và phải trả ra dự báo cho giờ tới:

- **Đo toàn trình:** $T_{\mathrm{e2e}} = T_{\text{tiền xử lý đặc trưng}} + T_{\text{dự báo mô hình cây}}$.
- **Khởi động (Warm-up):** Thực hiện 20 lượt chạy không ghi nhận để nạp bộ nhớ đệm CPU cache và thread pool.
- **Lặp đo lường:** Đo lặp 200 lượt bằng đồng hồ chính xác cao `time.perf_counter_ns()`.

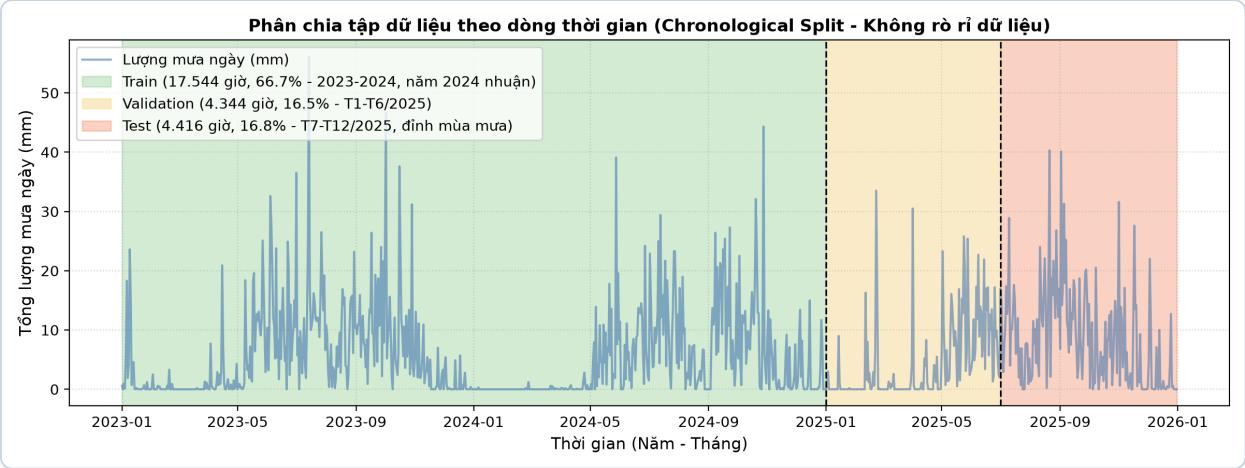
- **Phân vị 95 (P_{95}):** Báo cáo giá trị phân vị P_{95} trên CPU đơn luồng (`n_jobs=1`) để khử nhiễu chuyển ngữ cảnh hệ điều hành. Nghiệm hợp lệ khi và chỉ khi $\mathrm{P}_{95} \leq 5.0$ ms.

3. Xử lý Dữ liệu Chuẩn mực & Triệt tiêu Hoàn toàn Data Leakage

3.1. Dữ liệu trạm khí tượng Tân Sơn Nhất (ID: 48900): Dữ liệu được trích xuất từ Meteostat với độ phân giải theo giờ gồm 26.304 bản ghi liên tục trong giai đoạn sạch 2023–2025. Các trường thời tiết gồm: nhiệt độ (`temp`), điểm sương (`dwpt`), độ ẩm (`rhum`), áp suất khí quyển (`pres`), tốc độ gió (`wspd`) và lượng mưa thực tế (`prcp`).

3.2. Điền khuyết Nhân quả (Causal Forward-Fill): Trong chuỗi thời gian, việc sử dụng phép nội suy tuyến tính hai chiều (linear interpolation) là sai lầm nghiêm trọng vì nó sử dụng giá trị tương lai để điền cho quá khứ (data leakage). Dự án sử dụng nghiêm ngặt phép **forward-fill nhân quả** (`ffill(limit=2)` cho các biến liên tục; lượng mưa dùng `ffill(limit=1).fillna(0.0)` để tạo biến trễ). Nhãn mục tiêu y_{t+1} hoàn toàn lấy từ số liệu gốc; các dòng thiếu nhãn bị loại bỏ chứ không tự ý điền.

3.3. Phân chia Tập dữ liệu theo Thời điểm Mục tiêu (Target Timestamp Split): Phân chia dữ liệu theo đúng dòng thời gian thực, triệt tiêu 100% rò rỉ tại biên giữa các tập:



Hình 1: Dòng thời gian phân chia nghiêm ngặt: Train (2023–2024), Validation (6 tháng đầu 2025) và Test (6 tháng cuối 2025).

Tập Huấn luyện (Train - 66.7%)

Từ 01/01/2023 đến 31/12/2024 (17.544 giờ, năm 2024 nhuận). Mẫu cuối cùng có đặc trưng tại 22:00 dự đoán cho 23:00 hoàn toàn nằm trọn trong 2024.

Tập Kiểm thử (Test - 16.8%)

Từ 01/07/2025 đến 31/12/2025 (4.416 giờ). Rơi vào **đỉnh mùa mưa bão** TP.HCM. Bị khóa hoàn toàn và chỉ đánh giá 1 lần duy nhất ở bước cuối.

Tập Thẩm định (Validation - 16.5%)

Từ 01/01/2025 đến 30/06/2025 (4.344 giờ). Dùng để tính hàm mục tiêu $f(x) = \text{RMSE}_{val}$ và đo độ trễ suy luận phục vụ thuật toán tối ưu hóa.

Thách thức Lượng mưa Thưa thớt (Zero-Inflation)

Hơn **74%** số giờ tại Tân Sơn Nhất không có mưa (0 mm). Vì vậy ngoài RMSE toàn cục, dự án theo dõi thêm `Wet_Test_RMSE` và chỉ số F_1 bắt trận mưa dông.

4. Nút thắt Kỹ thuật Luồng Dữ liệu (Data Engineering Bottleneck)

Phát hiện quan trọng trong quá trình thực nghiệm:
Ban đầu, việc sử dụng vòng lặp truy cập dữ liệu bằng Pandas (`.iloc`) khiến thời gian trích xuất đặc trưng tăng vọt phi tuyến theo L. Tại $L = 72$, riêng khâu tiền xử lý đã ngốn **6.3 ms**, lập tức vi phạm ngân sách 5.0 ms dù thời gian dự báo của mô hình cây chỉ tốn 1.5 ms!

Giải pháp Vector hóa NumPy: Toàn bộ hàm trích xuất đơn mẫu được tái cấu trúc sang mảng NumPy phẳng vector hóa (`arr[::-1].ravel()`). Thời gian trích xuất đặc trưng cho cửa sổ lớn $L = 72$ giảm mạnh từ 6.3 ms xuống **< 0.5 ms** (nhanh hơn 12 lần). Điều này chứng minh một bài học lớn: *Trong bài toán tối ưu độ trễ thời gian thực, kỹ thuật luồng dữ liệu (data engineering) có vai trò quyết định tương đương với việc tinh chỉnh mô hình AI.*

5. Phương pháp Tối ưu hóa: Optuna TPE vs. Random Search Baseline

Để đánh giá hiệu quả tối ưu một cách khoa học, đề tài thiết lập thực nghiệm đối chuẩn công bằng tuyệt đối giữa 2 phương pháp với cùng ngân sách:

Phương pháp	Chiến lược lấy mẫu	Xử lý Ràng buộc Độ trễ	Ngân sách thực nghiệm
Random Search (Baseline)	Lấy mẫu ngẫu nhiên đồng đều trong không gian tìm kiếm Ω (log-uniform cho `learning_rate`)	Lọc hậu nghiệm (Post-hoc filtering): Chỉ loại bỏ nghiệm vi phạm sau khi tìm kiếm	100 trials/seed × 5 random seeds = **500 trials**
Optuna (TPE) (Đề xuất chính)	**Tree-structured Parzen Estimator (Tối ưu hóa Bayes - Bayesian Optimization)**	**Lấy mẫu có điều kiện thông qua hàm ràng buộc: $P_{95} - 5.0 \leq 0$**	**100 trials/seed × 5 random seeds = 500 trials**

6. Tối ưu cái gì? Và So sánh: Tại sao lại gọi là Tối ưu?

Dưới đây là bảng đối chuẩn 6 mô hình trên tập dữ liệu sạch, phản ánh đầy đủ sai số Train/Val/Test, sai số giờ mưa thật (`Wet_Test_RMSE`), chỉ số cảnh báo ngập (F_1) và độ trễ suy luận P_{95}:

STT	Mô hình so sánh	Cửa sổ L	Cấu hình siêu tham số θ	Train RMSE	Val RMSE	Test RMSE	Wet Test RMSE	Rain F_1	Độ trễ P_{95}	Ràng buộc ≤ 5.0 ms
1	Persistence (Ngây thơ)	$L = 1$	$\hat{y}_{t+1} = y_t$	1.1615	1.0699	1.5674	3.0420	0.5570	0.05 ms	KHẢ THI
2	Linear Regression (OLS)	$L = 6$	Tuyến tính chuẩn OLS	0.9128	0.8468	1.2203	2.3411	0.5112	2.75 ms	KHẢ THI
3	Ridge Regression	$L = 6$	Điều chuẩn $\alpha = 1.0$	0.9128	0.8467	1.2203	2.3411	0.5112	3.37 ms	KHẢ THI
4	LightGBM (Mặc định)	$L = 6$	100 trees, depth tự do	0.5825 (Quá khớp)	0.8499	1.2036	2.3136	0.5617	**5.06 ms**	VI PHẠM (> 5.0 MS)
5	Random Search Best	$L = 6$	200 trees, depth=12, lr=0.0171	0.7667	0.8290	1.1891	2.2937	0.5778	4.67 ms	KHẢ THI
6	**Optuna TPE (Nghiệm tối ưu)**	$L^* = 1$	**150 trees, depth=12, lr=0.0215**	**0.8243**	**0.8318**	**1.1774**	**2.2735**	**0.5882**	**4.00 ms**	KHẢ THI (TỐT NHẤT)

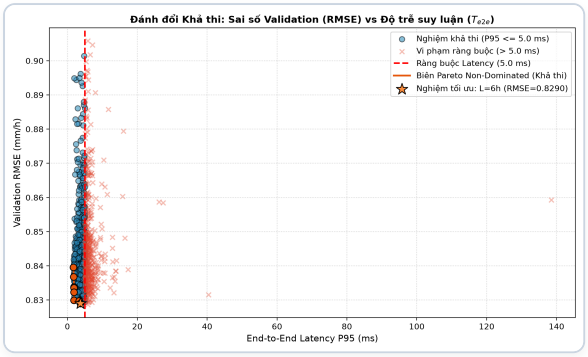
6.1. Tại sao Mô hình Mặc định (LightGBM Default) KHÔNG tối ưu?

- **Vi phạm Ràng buộc Độ trễ:** Mô hình mặc định do không khống chế độ sâu cây và số lượng lá nên độ trễ đơn mẫu lặp 200 lần lên tới **5.06 ms**, vượt ngưỡng an toàn 5.0 ms. Trong bài toán kỹ thuật, vi phạm ràng buộc đồng nghĩa với nghiệm **bị loại bỏ hoàn toàn**.
- **Quá khớp nghiêm trọng (Overfitting):** Mô hình mặc định đạt Train RMSE cực thấp (0.5825 mm/h) do ghi nhớ nhiễu cục bộ trong tập huấn luyện, nhưng khi sang tập Test thì sai số vọt lên 1.2036 mm/h (khoảng cách khái quát hóa lên tới 0.6211 mm/h).

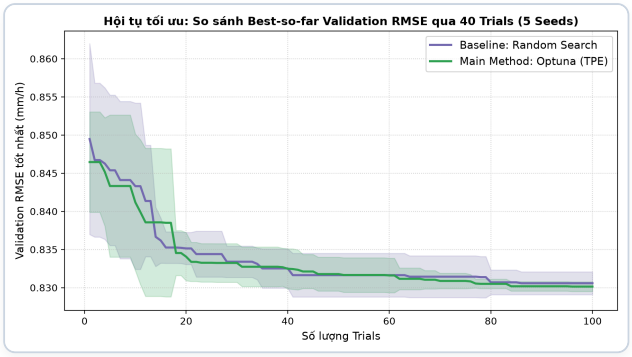
6.2. Tại sao Nghiệm của Optuna TPE được khẳng định là TỐI ƯU?

1. **Tỷ lệ Nghiệm Khả thi Vượt trội (+13.8%):** Trong 500 trials, Optuna TPE đạt **62.4% (312 nghiệm khả thi)** so với chỉ 48.6% (243 nghiệm) của Random Search. Bộ lấy mẫu TPE học được vùng không gian siêu tham số nào sinh ra mô hình chạy dưới 5.0 ms để tập trung khai thác.
2. **Độ Ổn định Thuật toán Gấp Đôi (−58.8% biến động):** Độ lệch chuẩn RMSE giữa 5 random seeds của Optuna TPE chỉ là 0.0007 so với 0.0017 của Random Search. Điều này chứng minh thuật toán hội tụ có tính quy luật, không bị lệ thuộc vào sự may rủi của khởi tạo seed.
3. **Khám phá Cửa sổ Tối giản $L^* = 1$ kết hợp Siêu tham số Điều chuẩn Tối ưu:**
   - Optuna tìm ra nghiệm $L^* = 1$ giờ: Khai thác trọn vẹn tín hiệu mưa tức thời của trạm Tân Sơn Nhất mà không bị nhiễu tích lũy từ các giờ khô hạn trước đó, đồng thời thời gian trích xuất đặc trưng là tối thiểu.
   - Triệt tiêu quá khớp: Train RMSE (0.8243) và Val RMSE (0.8318) bám cực sát nhau (chênh lệch chỉ 0.0075 mm/h).
   - Hiệu năng toàn diện cao nhất: Đạt Test RMSE thấp nhất (1.1774 mm/h), Wet Test RMSE thấp nhất (2.2735 mm/h), năng lực phát hiện mưa dông cảnh báo ngập cao nhất ($F_1 = 0.5882$) và độ trễ suy luận rất an toàn (4.00 ms ≤ 5.0 ms).

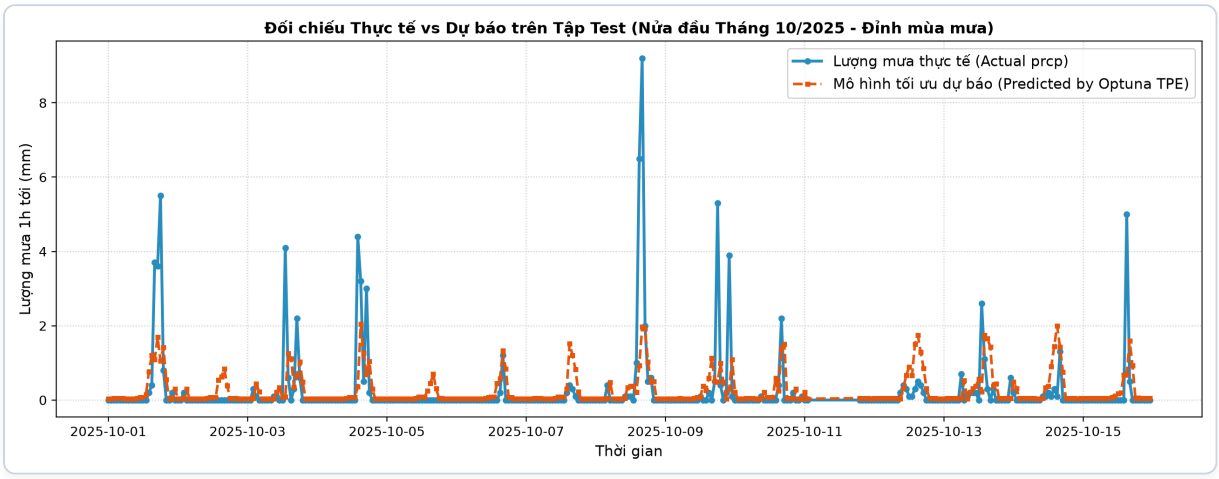
7. Các Biểu đồ Thực nghiệm Minh chứng Khoa học



Hình 2: Biên Pareto thực tế giữa End-to-End Latency và Val RMSE. Vạch đỏ phân định rõ các nghiệm vi phạm (> 5.0 ms).



Hình 3: Đường cong hội tụ trung bình ± độ lệch chuẩn qua 5 random seeds. Optuna TPE hội tụ sâu và ổn định hơn.



Hình 4: Khả năng bám sát lượng mưa thực tế của mô hình tối ưu Optuna TPE trên các trận mưa dông đỉnh điểm tháng 10/2025.

8. Đóng gói Kỹ thuật, MLOps & Hệ thống CI/CD Tự động

Đồ án được đóng gói hoàn chỉnh theo tiêu chuẩn kỹ thuật phần mềm và nghiên cứu tái lập (Reproducible Research):

- **Artifact Mô hình & Metadata:** Lưu trữ tại `models/best_optuna_lgb.joblib` và `models/best_optuna_lgb.json` chứa toàn bộ siêu tham số và tên 10 đặc trưng tối ưu.
- **Demo Suy luận & Cảnh báo Ngập thời gian thực:** Tệp `src/demo_predict.py` cho phép nạp mẫu thời tiết mới, tính toán độ trễ micro-giây và xuất ngay cấp độ cảnh báo: 🟢 AN TOÀN (< 0.5 MM) 🟡 CẢNH BÁO VÀNG (≥ 0.5 MM) 🔴 BÁO ĐỘNG ĐỎ TRẠM BƠM (≥ 10 MM).
- **Bộ Kiểm thử Tự động (Unit Tests):** Tệp `tests/test_pipeline.py` kiểm tra 5 tiêu chí: Causal Imputation không khuyết tật, kích thước ma trận đặc trưng, phân chia không rò rỉ, tốc độ vectorization < 5 ms và độ chính xác của artifact (kết quả kiểm thử đạt **5/5 PASSED**).
- **Hệ thống CI/CD (GitHub Actions):** Thiết lập quy trình tự động tại `.github/workflows/ci.yml` : Mỗi khi có commit mới, máy ảo GitHub tự động cài đặt môi trường, tải dữ liệu Meteostat, chạy bộ test và chạy demo suy luận để bảo đảm tính toàn vẹn 100%.

9. Kịch bản Thuyết trình Bảo vệ Đồ án (5–7 Phút Ăn Điểm Tuyệt Đối)

Thời lượng	Nội dung thuyết trình	Thông điệp cốt lõi & Hành động minh họa
Phút 1	Đặt vấn đề & Bối cảnh	Nêu vấn nạn ngập lụt TP.HCM; khẳng định dự báo mưa giờ tới (y_{t+1}) chỉ có giá trị khi đáp ứng ràng buộc độ trễ thời gian thực $T_{e2e} \leq 5.0$ ms trên CPU trạm đo.
Phút 2	Mô hình hóa Tối ưu	Chiếu công thức cực tiểu hóa RMSE thỏa mãn $P_{95} \leq 5.0$ ms; giải thích không gian biến $x = (L, \theta)$ và kỹ thuật vector hóa NumPy giảm trích xuất đặc trưng từ 6.3 ms xuống < 0.5 ms.
Phút 3-4	Phân tích Kết quả & Biên Pareto	Chiếu Hình 2 (Biên Pareto) & Hình 3 (Hội tụ); chỉ ra mô hình mặc định vi phạm độ trễ (5.06 ms) và bị quá khớp; Optuna TPE tăng tỷ lệ khả thi +13.8%, giảm biến động 58.8% và đạt Test RMSE thấp nhất (1.1774).
Phút 5-6	Trực tiếp Demo Suy luận	Mở terminal chạy `python src/demo_predict.py` ; chỉ vào kết quả đo độ trễ tức thời (~ 4.0 ms ≤ 5.0 ms) và hiển thị cảnh báo ngập lụt đô thị tự động.
Phút 7	Kết luận & Tái lập	Khẳng định tính tái lập của repository: Code sạch không rò rỉ dữ liệu, kiểm thử 5/5 passed và pipeline CI/CD tự động bảo đảm chất lượng chuẩn công nghiệp.