TỔNG QUAN ĐỀ TÀI ĐỒ ÁN

TỐI ƯU HÓA DỰ BÁO LƯỢNG MƯA THEO GIỜ DƯỚI RÀNG BUỘC ĐỘ TRỄ SUY LUẬN

Project Overview v0.1 - chốt ý tưởng đến giai đoạn thu thập & kiểm tra dữ liệu

Môn	Nhập môn Tối ưu hóa
Định hướng	Supervised time-series forecasting + constrained hyperparameter optimization
Dataset ưu tiên	Meteostat - Ho Chi Minh / Tan Son Nhat, station 48900
Ngày cập nhật	27/10/2026

MỐC DỪNG CỦA TÀI LIỆU Tài liệu này dừng sau khi xác định dataset, cách tải, cấu trúc lưu trữ và checklist audit dữ liệu. Chưa khóa mô hình cuối cùng, chưa chạy HPO, chưa đo latency thực nghiệm.

1. Tóm tắt ý tưởng đã chốt

Bài toán cốt lõi: dự báo lượng mưa của giờ kế tiếp tại một trạm khí tượng, đồng thời tìm cấu hình mô hình có sai số dự báo thấp nhất nhưng vẫn thỏa ràng buộc thời gian suy luận không vượt quá 5 ms.

Cách nhìn theo tối ưu hóa: không chỉ "train một model dự báo mưa", mà xem mỗi tổ hợp độ dài cửa sổ lịch sử và hyperparameter là một nghiệm ứng viên; nghiệm chỉ hợp lệ khi đáp ứng latency constraint.

Tên đề tài	Tối ưu hóa dự báo lượng mưa theo giờ dưới ràng buộc độ trễ suy luận
Đối tượng dự báo	Lượng mưa 1 giờ tiếp theo tại trạm khí tượng
Decision variables	x = (L, θ): L là độ dài cửa sổ lịch sử; θ là hyperparameters/cấu hình mô hình
Objective	Minimize validation forecasting error (ưu tiên RMSE; theo dõi thêm MAE)
Constraint	Inference latency ≤ 5 ms cho một lần dự báo theo protocol phần sau
Baseline dự kiến	Cửa sổ L cố định + cấu hình model mặc định, chưa tuning

LƯU Ý VỀ δ Ngưỡng δ "chống nhiễu mưa bão" chưa đưa vào formulation chính. Chỉ bổ sung δ nếu audit dữ liệu chứng minh có sensor noise/outlier và ta định nghĩa rõ δ xử lý lỗi đo chứ không xóa các trận mưa lớn thật.

2. Bối cảnh và vấn đề nghiên cứu

Mưa lớn trong thời gian ngắn có thể làm hệ thống thoát nước đô thị quá tải, gây ngập cục bộ và làm gián đoạn giao thông. Dự báo lượng mưa ở độ phân giải theo giờ có thể hỗ trợ cảnh báo sớm và ra quyết định vận hành. Tuy nhiên, hệ thống cảnh báo thời gian thực không chỉ cần dự báo tốt mà còn phải phản hồi nhanh.

Vấn đề nghiên cứu của đồ án vì vậy được diễn đạt gọn như sau:**"Với giới hạn suy luận tối đa 5 ms, nên dùng bao nhiêu giờ lịch sử và cấu hình mô hình nào để sai số dự báo lượng mưa giờ kế tiếp là nhỏ nhất?"**

3. Hướng triển khai tổng thể

Dữ liệu theo giờ	Audit & làm sạch	Tạo cửa sổ L	Baseline	Optimization + constraint	Test cuối

Ở giai đoạn hiện tại, project dừng tại hai ô đầu: chọn nguồn dữ liệu, tải dữ liệu, bảo toàn raw data và audit chất lượng trước khi tạo sliding window hoặc train model.

4. Dataset: lựa chọn chính và phương án dự phòng

4.1. Lựa chọn chính: Meteostat - Tan Son Nhat (48900)

Trạm: Ho Chi Minh / Tan Son Nhat; Meteostat ID 48900; WMO 48900; ICAO VVTS; tọa độ khoảng 10.8167, 106.6667; múi giờ Asia/Ho_Chi_Minh. Theo trang trạm Meteostat, inventory hourly bắt đầu từ năm 1949 và vẫn còn cập nhật trong 2026.

Cột	Ý nghĩa	Đơn vị
time	Thời điểm quan trắc	timestamp
temp	Nhiệt độ không khí	°C
rhum	Độ ẩm tương đối	%
prcp	Tổng lượng mưa trong 1 giờ	mm
wdir	Hướng gió	°
wspd	Tốc độ gió	km/h
wpgt	Gió giật	km/h
pres	Áp suất mực biển	hPa
coco	Mã điều kiện thời tiết	code

Khoảng thời gian đề xuất ban đầu: 01/01/2015 - 31/12/2025. Nếu đủ liên tục, đây là tối đa 96.432 timestamp theo giờ trước khi xét missing records.

4.2. Vì sao phù hợp với đồ án

- Đúng độ phân giải theo giờ và có biến prcp là tổng lượng mưa một giờ - khớp trực tiếp với target.
- Một trạm duy nhất giúp scope gọn, dễ tái lập và phù hợp 5 tuần.
- Có nhiều biến khí tượng cùng timestamp nên có thể bắt đầu từ bài toán univariate rồi mở rộng multivariate nếu cần.
- Nguồn công khai, tải được bằng Python hoặc file dump, thuận lợi cho GitHub reproducibility.
- Có source columns trong file dump, hữu ích để audit provenance từng biến.

4.3. Hai phương án dự phòng

Nguồn	Loại dữ liệu	Khi nào dùng	Trade-off
NOAA GHCNh	Quan trắc trạm theo giờ	Nếu cần provenance chính thức mạnh hơn hoặc cần kiểm tra chéo Meteostat	Format/quality flags phức tạp hơn, preprocessing nặng hơn
ERA5-Land time-series	Reanalysis grid 0.1° (~9 km), hourly	Nếu dữ liệu trạm mưa thiếu quá nhiều hoặc cần chuỗi đầy đủ hơn	Không còn là quan trắc trực tiếp tại trạm; phải đổi framing sang khu vực/grid point

5. Cách tải dữ liệu Meteostat và tổ chức dữ liệu

5.1. Cách A - dùng Python library (khuyên dùng để làm notebook)

Cách này tiện cho exploratory work và sau này tái chạy bằng script. Dùng station ID 48900, chỉ định thời gian và múi giờ.

```
from datetime import datetime
import meteostat as ms

start = datetime(2015, 1, 1)
end   = datetime(2025, 12, 31, 23, 59)

station = ms.Station(id='48900')
ts = ms.hourly(
    station,
    start,
    end,
    timezone='Asia/Ho_Chi_Minh'
)

df = ts.fetch()
df.to_csv('data/raw/meteostat_48900_2015_2025.csv')
print(df.shape)
print(df.head())
```

5.2. Cách B - tải file CSV.gz theo năm, không cần API key

Meteostat công bố time-series dump cho từng trạm và từng năm. Endpoint chính thức có dạng:

```
https://data.meteostat.net/hourly/{year}/{station}.csv.gz
```

Với Tân Sơn Nhất, ví dụ năm 2025:

```
https://data.meteostat.net/hourly/2025/48900.csv.gz
```

Có thể tải hàng loạt 2015-2025 bằng shell:

```
mkdir -p data/raw/meteostat_48900
for y in {2015..2025}; do
  curl -L "https://data.meteostat.net/hourly/${y}/48900.csv.gz" \
    -o "data/raw/meteostat_48900/48900_${y}.csv.gz"
done
```

TẠI SAO NÊN GIỮ CẢ FILE RAW? Để có thể tái lập, đối chiếu nguồn, kiểm tra lại missing/source columns và tránh việc notebook vô tình sửa dữ liệu gốc. Raw data nên là read-only trong tư duy project.

5.3. Cấu trúc thư mục đề xuất

```
rainfall-forecast-optimization/
├── data/
│   ├── raw/                # file tải nguyên gốc, không sửa
│   ├── interim/            # dữ liệu sau chuẩn hóa timestamp / merge
```

```
│   └── processed/          # dành cho dataset model-ready sau này
├── notebooks/
│   └── 01_data_audit.ipynb
├── src/
│   └── data/
│       ├── download.py
│       └── audit.py
├── reports/figures/
├── requirements.txt
└── README.md
```

6. Data audit cần làm trước khi modeling

Đây là bước cuối của tài liệu này. Mục tiêu không phải "làm đẹp dữ liệu" ngay, mà là hiểu dữ liệu có đáng tin để tiếp tục hay không.

Kiểm tra	Câu hỏi cần trả lời	Output nên lưu
Coverage thời gian	Có đủ timestamp theo giờ 2015-2025 không? Có gap dài ở giai đoạn nào?	Bảng số giờ kỳ vọng vs thực tế, danh sách gap
Missingness	prcp/temp/rhum/pres/wspd thiếu bao nhiêu %? Missing có tập trung theo năm/mùa không?	missing_rate.csv + heatmap/timeline
Rain sparsity	Bao nhiêu % giờ có prcp = 0, >0, mưa lớn?	distribution + quantiles
Outlier vật lý	Có giá trị âm, spike bất hợp lý, duplicate timestamp không?	audit_flags.csv
Provenance	Các cột *_source đến từ nguồn nào? Có dấu hiệu model-filled data không?	source_summary.csv
Timezone	Timestamp đang là UTC hay local? Có chuyển sang Asia/Ho_Chi_Minh nhất quán chưa?	metadata.json
Target usability	prcp có đủ coverage để làm y(t+1) không?	go/no-go note

6.1. Các thống kê tối thiểu nên xuất

- Số dòng, min/max timestamp, số duplicate timestamp.
- Missing rate từng cột và từng năm.
- Tỷ lệ prcp = 0, prcp > 0; median, p90, p95, p99 của prcp dương.
- Histogram/ECDF của prcp; biểu đồ theo tháng để nhìn seasonal pattern.
- Top các gap thời gian dài nhất.
- Tỷ lệ source/provider cho prcp và các feature quan trọng.

6.2. Gate để quyết định có tiếp tục với Meteostat hay không

Tình huống	Quyết định	Hành động
prcp coverage tốt, gap nhỏ	GO	Giữ Meteostat 48900 làm dataset chính
prcp thiếu vừa phải nhưng có thể giải thích	GO có điều kiện	Thu hẹp khoảng năm hoặc xử lý missing có kiểm soát
prcp thiếu nhiều / model-filled quá nhiều	SWITCH / CROSS-CHECK	Kiểm tra NOAA GHCNh cho cùng trạm; nếu vẫn kém, cân nhắc ERA5-Land

ĐIỂM DỪNG Khi đã có raw data + báo cáo audit + quyết định GO/NO-GO cho Meteostat, phần "data stage" coi như hoàn tất. Từ đây mới chuyển sang thiết kế forecast target, split thời gian, baseline và optimization.

7. Những gì đã chốt và những gì cố ý chưa chốt

Hạng mục	Trạng thái	Ghi chú
Tên đề tài	Đã chốt	Tối ưu hóa dự báo lượng mưa theo giờ dưới ràng buộc độ trễ suy luận
Target horizon	Tạm chốt	Dự báo 1 giờ tiếp theo
Latency constraint	Đã chốt về ý tưởng	≤ 5 ms; protocol đo sẽ chốt sau khi có baseline
Dataset chính	Tạm chốt	Meteostat 48900, 2015-2025; phải qua audit
Decision variable L	Đã chốt	Historical window length sẽ được tối ưu
δ chống nhiễu	Chưa dùng	Chỉ thêm nếu audit chứng minh cần
Model family	Chưa khóa	XGBoost/GBDT hoặc model nhẹ là ứng viên; quyết định sau baseline
Metric chính	Chưa khóa hoàn toàn	RMSE là ứng viên chính; MAE dùng bổ sung
HPO method	Chưa khóa	Random Search vs Optuna/TPE sẽ quyết định sau khi pipeline baseline ổn

8. Nguồn tham khảo và provenance

Nguồn môn học: Hướng dẫn phạm vi đề bài tập lớn cá nhân - Nhập môn Tối ưu hóa, Khoa CNTT, Trường Đại học Văn Lang. Tài liệu yêu cầu optimization là trung tâm, có decision variables/objective/constraints, baseline, đánh giá công bằng, và GitHub có khả năng tái lập.

- Meteostat - trạm Ho Chi Minh / Tan Son Nhat 48900
- Meteostat Developers - Hourly time-series dumps
- Meteostat Developers - Hourly Python API
- Meteostat Developers - Meteorological parameters
- NOAA NCEI - GHCNh documentation
- Copernicus - ERA5-Land hourly time-series

Ghi chú provenance: Meteostat tổng hợp dữ liệu từ nhiều nguồn (historical databases, METAR, SYNOP) và annual dumps có thể bao gồm dữ liệu mô hình dùng để bù khoảng trống. Vì vậy audit các *_source columns và mức độ model-filled data là bắt buộc trước khi tuyên bố đây là “quan trắc thuần trạm”.